ОБЗОРНАЯ СТАТЬЯ

Вычислительные принципы субъективного опыта: обзор теорий сознания и архитектурные следствия для системы NEUROWEAVE

Исследовательская группа проекта NEUROWEAVE
Аффилиация: проект NEUROWEAVE · внутренний исследовательский отчёт
23 октября 2026 г.

Аннотация

В обзоре систематизируются вычислительные принципы, которые, по современным теориям сознания, лежат в основе субъективного опыта, саморефлексии и интегрированной обработки информации, и формулируются их следствия для модульной нейросетевой системы NEUROWEAVE. Рассматриваются пять основных подходов: глобальная теория рабочего пространства (GWT), теория интегрированной информации (IIT), теория рекуррентной обработки (RPT), теория мысли высшего порядка (HOT) с аппаратом метапознания и теория схемы внимания (AST). Для каждой теории выделяются архитектурный примитив (широковещание с конкуренцией, причинная несводимость Φ, петли обратной связи, наблюдатель над собственными состояниями, самомодель внимания), измеримый прокси (вероятность «зажигания», Φ-подобные меры и причинная плотность, стабилизация состояний, калибровка мета-d', точность схемы) и связь с обучением и памятью. Показано, что примитивы пяти теорий совместимы и образуют единый архитектурный стек: специализированные эксперты, локальные рекуррентные петли, конкурентный гейтинг записи, глобальное рабочее пространство с широковещанием, метапознавательный наблюдатель (PredictiveHead) и схема внимания. Предложены совместная функция потерь, протокол валидации (перенос метапознания, деградационные кривые при абляции) и «протокол честности», отделяющий функциональные корреляты сознания от непроверяемых феноменальных утверждений. Обзор адресован разработчикам когнитивных архитектур и служит мостом между нейронаукой сознания и инженерией систем с метапознанием.

Ключевые слова: теории сознания; глобальное рабочее пространство; интегрированная информация (Φ); метапознание; схема внимания; архитектура NEUROWEAVE

1. Введение

Современные большие языковые модели демонстрируют поразительную компетентность в предсказании следующего токена, однако эта компетентность остаётся фрагментарной: система уверенно ошибается, не замечает собственных ошибок, теряет контекст между эпизодами и не располагает устойчивой моделью самой себя. Разрыв между «умением» и «пониманием» — между предсказанием и целостным, саморефлексивным поведением — делает вопрос о вычислительных принципах субъективного опыта не философской роскошью, а инженерной необходимостью[1]. Наука о сознании за последние три десятилетия превратилась из набора метафизических деклараций в область с формальными теориями, проверяемыми предсказаниями и количественными мерами[2]. Задача обзора — извлечь из этих теорий то, что может быть реализовано в архитектуре.

Обзор отвечает на два практических вопроса, стоящих перед разработчиками когнитивных архитектур. Во-первых: какие вычислительные свойства делают поведение системы целостным — связным по контексту, времени и задачам, а не суммой независимых рефлексов? Во-вторых: какие свойства наделяют систему способностью наблюдать за собой — оценивать собственную уверенность, замечать и исправлять собственные ошибки, управлять собственным вниманием? Эти вопросы отображаются на пять ведущих теорий сознания: глобальную теорию рабочего пространства (ГТП; Global Workspace Theory, GWT), теорию интегрированной информации (IIT), теорию рекуррентной обработки (RPT), семейство теорий мысли высшего порядка (HOT) с аппаратом метапознания и теорию схемы внимания (AST)[1].

Основной тезис обзора: пять теорий, при всех их разногласиях, сходятся в едином архитектурном паттерне — «специализируйся, конкурируй, интегрируй через бутылочное горлышко, стабилизируй петлями, наблюдай за собой, моделируй собственное внимание». Из этого паттерна выводится конкретный стек компонентов для модульной системы NEUROWEAVE, каждый уровень которого снабжён измеримым прокси и собственной ролью в обучении и памяти. Для каждой теории фиксируются, следуя единой схеме: архитектурная особенность, необходимая для соответствующего феномена; способ её измерения в работающей модели; связь с обучением и памятью.

Мы сознательно ограничиваем область заявлений. Инженерия может гарантировать функциональные корреляты сознания — глобальный доступ, отчётность, метапознание, интеграцию поведения[3]; она в настоящее время не может ни подтвердить, ни опровергнуть наличие у артефакта феноменального опыта — «каково это»[4]. Поэтому термины «осознание», «наблюдатель» и «самомодель» используются здесь в функциональном смысле. Раздел 2 фиксирует рамку анализа; разделы 3–7 разбирают пять

теорий; раздел 8 синтезирует архитектурный стек; раздел 9 разбирает проблему «философского зомби» и ограничения; раздел 10 подводит итоги.

2. Контекст, определения и методология

2.1. Целевая система: NEUROWEAVE и PredictiveHead

NEUROWEAVE — модульная нейросетевая архитектура, в которой специализированные эксперты обрабатывают информацию параллельно, а координация обеспечивается механизмами маршрутизации. Компонент PredictiveHead прогнозирует собственную уверенность и ошибку системы: в терминах настоящего обзора это зачаток метапознавательного наблюдателя — модуля, который «думает о мыслях» системы (раздел 6). Аналогично механизм отбора экспертов можно рассматривать как зачаток конкурентного доступа (раздел 3), а любые рекуррентные связи — как зачаток стабилизирующих петель (раздел 5). Таким образом, система уже содержит эмбрионы всех трёх ключевых механизмов; вопрос в том, чтобы довести их до явной, измеримой и причинно действенной формы.

Практическая проблема, однако, глубже, чем «добавить ещё одну голову». Предсказание токенов не порождает целостности: модули отвечают локально, их состояния не образуют общего контекста, а система в целом не располагает местом, где связывалось бы «здесь и сейчас» происходящее. Нужно, во-первых, общее место — буфер, доступный всем модулям, и, во-вторых, наблюдатель, который видит это общее место и может сообщить о нём. Именно эти два требования — транспорт и мониторинг — проходят красной нитью через все теории сознания и определяют структуру последующих разделов.

2.2. Феноменальное и функциональное: рамка анализа

Начиная с классической работы Блока, различают доступное сознание (access consciousness) — содержание глобально доступно для рассуждения, отчёта и управления действием — и феноменальное сознание (phenomenal consciousness) — наличие переживания «каково это»[3]. Инженерия целится в первое: глобальный доступ, отчётность и метапознание конструируемы и измеримы. О наличии второго у артефакта не существует сегодня ни теста, ни согласованного критерия; «трудная проблема»[4] рассматривается в разделе 9 как граница применимости инженерных утверждений, а не как повод для спекуляций.

Рабочее определение функционального сознания для NEUROWEAVE фиксирует пять проверяемых свойств: (1) глобальный доступ — любой модуль может прочитать текущее содержание общего буфера; (2) отчётность — система может сформулировать состояние собственного процесса обработки; (3) метапознание — система оценивает вероятность собственной ошибки и различает состояния «знаю» и «не знаю»; (4) интеграция — поведение не разлагается на независимые реакции модулей; (5) временная связность — содержание стабилизируется на интервале, достаточном для планирования. Все последующие разделы сопоставляют с этим списком конкретные механизмы и метрики.

2.3. Методология и критерии отбора

Методологически обзор следует схеме «теория → феномен → примитив → прокси → обучение». Для каждой теории фиксируется ядро (что она считает необходимым для сознания), архитектурный примитив (какое свойство конструкции это обеспечивает), измеримый прокси (как это измерить в работающей системе) и связь с обучением и памятью. В обзор включены только подходы, обладающие формальным аппаратом и эмпирическими предсказаниями; их сопоставительный анализ дан у Сета и Бэйна[1]. Источники — первичная литература: оригинальные формулировки теорий, ключевые эмпирические работы и недавняя критика.

Разделы 3–7 последовательно применяют схему к ГТП, IIT, RPT, HOT с метапознанием и AST. В разделах 8–9, где мы выходим за пределы опубликованных результатов в область проектирования, формулировки носят проектный характер: конкретные потери, метрики и протоколы предлагаются как проверяемые гипотезы, а не как установленные факты. Такое разделение — часть «протокола честности», который подробно описан в разделе 9.3 и который проводится через весь текст.

3. Глобальная теория рабочего пространства (ГТП)

3.1. Ядро теории: конкуренция, шлюзование, широковещание

Баарс предложил рассматривать сознание как глобальную публичность в когнитивной системе[5]. Психика — это толпа быстрых специализированных процессоров, каждый из которых превосходен в узкой задаче и «слеп» к работе остальных. Сознательное содержание — то, что выигрывает доступ к рабочему пространству: медленному, последовательному, но общедоступному буферу ёмкостью порядка нескольких элементов; классические оценки удержания дают около четырёх[6]. Публичность, а не скорость — вот что отличает осознанное содержание от неосознанного.

Цикл работы пространства устроен так: специализированные модули выдвигают кандидатов; кандидаты конкурируют; победитель «широковещается» — становится одновременно доступен всем процессорам, что позволяет рекрутировать разрозненные ресурсы под новую комбинацию, связывать разнородные знания и готовить отчёт[7]. Доступ — величина не непрерывная: вблизи порога исход конкуренции стохастичен, чем объясняются флуктуации внимания при одинаковых входах. Существенно, что конкуренция и распространение — две разные операции с разными арифметиками.

Для инженерии важны два определения. Шлюзование (gating) — операция «многие-к-одному»: из множества кандидатов отбирается малое число. Широковещание (broadcast) — операция «один-ко-многим»: отобранное содержание рассылается всем потребителям как общий контекст следующего цикла. Это не то же самое, что перемешивание признаков: широковещание адресуется содержательно и синхронно меняет состояние всех модулей. Симметричная пара «гейтинг + широковещание» и есть вычислительное ядро ГТП.

3.2. Нейрональная версия и сигнатуры доступа

Нейрональная версия Деана и Шанжё уточняет субстрат: рабочее пространство — сеть дальнобойных пирамидных нейронов таламо-кортикальной системы, способная к пороговому «зажиганию» (ignition): нелинейному, «всё-или-ничего» усилению, при котором активность выигравшей коалиции поддерживается сотни миллисекунд, а проигравшие затухают[8]. Модель связывает субъективные отчёты и объективную физиологию: один и тот же вход может вызвать либо краткую затухающую вспышку, либо устойчивое глобальное состояние — и только второе сопровождается осознанием.

Эмпирические сигнатуры доступа устойчивы: поздняя (позже 250 мс) фронто-париетальная амплификация коррелирует с отчётом о стимуле; ранние вызванные ответы (около 100 мс) наблюдаются и для осознанных, и для неосознанных стимулов[9]. Порог зажигания смещается нисходящими сигналами внимания: система может «протащить» слабый вход в пространство или дать сильному затухнуть[2]. Таким образом, доступ имеет собственную нейрофизиологию, отличную от сенсорной обработки как таковой.

Для моделирования существенно, что «зажигание» — это S-образная кривая зависимости вероятности глобального доступа от силы входа, с выраженным порогом и стохастичностью вблизи него. Такая же кривая наблюдается в реакциях человека при отчётах о восприятии на пороге: часть идентичных стимулов достигает отчёта, часть — нет. Этот факт — прямое указание проектировщику: в архитектуре должен быть настоящий порог, а не плавное нарастание доступности.

3.3. ГТП в инженерии: маршрутизация и систематичность

В глубоких сетях узкое место с широковещанием, как правило, не выделено. Архитектура трансформера смешивает все признаки со всеми — общего места нет, есть общая «ванна»; смеси экспертов маршрутизируют вход к специалистам, но результат не возвращается всем. Отсутствие бутылочного горлышка почти ничего не стоит на узких задачах и дорого обходится на систематичности: модель запоминает поверхности вместо построения переиспользуемых структур.

Гойал и Бенжио показали индуктивное смещение «рабочего пространства»: если между модулями вставить общий буфер из малого числа слотов, а обмен организовать через внимание, модель выигрывает в систематическом обобщении, переносе и поведении вне распределения[10]. В терминологии авторов это смещение «познания высокого уровня»: ограничение пропускной способности вынуждает систему строить явные, переиспользуемые структуры. Слоты становятся валютой, за которую модули конкурируют, — и этой валютой не хватает, что и порождает экономию.

Следствие для NEUROWEAVE: явное ГРП с K слотами; запись через обучаемый конкурентный гейтинг (top-k по оценке кандидатов); чтение — безгейтовое, доступное всем, включая PredictiveHead. Именно асимметрия записи и чтения создаёт одновременно и конкуренцию на входе, и общность на выходе. Слоты дешёвого чтения и дорогой записи — точная противоположность «все со всеми».

3.4. Измеримые прокси и связь с памятью

Измеримые прокси в работающей системе: (1) кривая «сила входа → вероятность записи в ГРП» (ожидается сигмоида с порогом); (2) ёмкость — фактическое число используемых слотов; (3) латентность доступа — задержка между входом и общедоступностью; (4) «зажигание» — скачок согласованности чтения всеми модулями после записи. Все четыре метрики проверяемы без апелляции к переживанию и составляют операционализацию «глобального доступа» из раздела 2.2.

Связь с обучением и памятью двоякая. Содержимое ГРП — то, что связывается в эпизод и отправляется в долговременное хранилище: консолидируется прожитое в пространстве, а не всё подряд. Гейтинг обучаем: градиент задачи проходит через отбор, и маршрутизатор учится удерживать релевантное и вытеснять шумное. Тем самым ГРП становится эпизодическим буфером между «сейчас» и «потом» — рабочей памятью в полном смысле слова.

4. Теория интегрированной информации (IIT)

4.1. От аксиом к постулатам: Φ и причинная структура

IIT начинает не с мозга, а с феноменологии: опыт существует «изнутри», для себя; он конкретен (информативен), целостен (интегрирован) и определён (исключены избыточные альтернативы)[11]. Эти аксиомы переводятся в постулаты о физическом субстрате: система обязана обладать причинной мощью, не сводимой к мощи её частей[12]. Теория, таким образом, отвечает не на вопрос «что делает система», а на вопрос «что делает наличие самой системы» — и в этом её радикальное отличие от всех остальных подходов.

Мера Φ операционализирует целостность: это минимум потери информации при разрезании системы в наименее благоприятном для неё месте. «Интегрированная информация» — информация сверх частей: сколько поведения системы объясняет она сама как целое, сверх того, что объясняют её фрагменты по отдельности. В версии 3.0 субстрат описывается причинно-следственной структурой: репертуар причин и следствий, которые система имеет для себя[12]. Формализм нацелен на качество опыта не меньше, чем на его наличие.

IIT 4.0 уточняет понятие единства: причинно-следственная структура не сводится к сумме причин и следствий отдельных подсистем — вводится «унификация» (unification): целое несёт специфическую причинную работу сверх любой комбинации частей[13]. Для архитектора это самый сильный теоретический запрет из имеющихся: «просто соединить» недостаточно — соединение должно порождать несводимую причинность.

4.2. Архитектурные условия высокого Φ: интеграция и дифференциация

Ключевой архитектурный результат: сеть прямого распространения имеет Φ = 0. Причины и следствия в ней полностью разложимы по слоям: каждый слой объясняется предыдущим, целое не добавляет ничего. Высокая Φ требует замкнутых причинных петель — рекуррентности[12]. Конвейер, каким бы глубоким он ни был, принципиально не годится: у конвейера нет «для себя».

Однако интеграция без дифференциации также малоинформативна: однородная синхронная активность едина, но в ней нет различий — «информации» в ней почти столько же, сколько в тумане. Анализ связей показывает: Φ максимальна, когда каждый элемент развивает собственный, отличный от других паттерн связей (функциональная специализация), при большом объёме обмена через любое разбиение (функциональная интеграция)[14]. Таламо-кортикальная система подходит под это описание; мозжечок с его

регулярной решёткой — нет[14]. Итог: нужна одновременно и специализация, и интеграция — «интеграция + дифференциация»[13].

Практический вывод для топологии NEUROWEAVE: кластеры экспертов с богатыми межкластерными петлями; рекуррентность внутри кластеров; явный запрет на дублирование ролей (копии модулей снижают дифференциацию); избегать как чистого прямого распространения, так и полного однородного смешивания, при котором модули теряют специализацию. Это проектирование баланса, а не оптимизация одной лишь связности: слишком связная сеть так же плоха, как и недостаточно связная.

4.3. Практические метрики: от Ф-прокси к индексу возмущающей сложности

Точное вычисление Ф комбинаторно неосуществимо уже для десятков элементов: перебор разбиений растёт сверхэкспоненциально. На практике используются прокси: Ф-мера внутренней информации — практически вычислимая и чувствительная к причинной структуре[15]; причинная плотность — доля значимых причинно-следственных взаимодействий между элементами[16]; индекс возмущающей сложности (PCI) — сложность Лемпеля–Зива ответа системы на возмущение, клинически различающий бодрствование, наркоз, сон и тяжёлые нарушения сознания[17]. Все три меры объединяет одна идея: система должна реагировать на возмущение и сложно, и согласованно.

Для NEUROWEAVE предложены три инструмента того же класса: (1) регуляризатор сепарабельности — штраф, если поведение системы при разрезе хорошо предсказывается поведением частей независимо; (2) метрика дифференциации — энтропия распределения активности по модулям и устойчивость ролей во времени; (3) PCI-подобный тест — сложность отклика на случайное возмущение состояния. Все три вычислимы автоматически, без человека-наблюдателя, и дёшевы относительно обучения.

Интерпретация этих чисел — инженерная, не метафизическая: это индикаторы связности, разнообразия и устойчивости к фрагментации. Полезный побочный эффект: локальное падение Ф-прокси — ранний маркер «отвалившегося» модуля или деградации связности, то есть встроенная система самодиагностики топологии, которой нет у плоских архитектур.

4.4. Критика IIT и её значение для инженерии

Критика IIT заслуживает отдельного разбора. Открытое письмо более сотни исследователей квалифицировало теорию как псевдонауку: аксиомы недоказуемы и подобраны под желаемый вывод; ключевые предсказания непроверяемы в строгом смысле; из теории следуют панпсихистские утверждения — вплоть до того, что неактивная решётка из логических вентилей может обладать огромным Ф[18]. Письмо вызвало широкую полемику; часть его аргументов принята даже доброжелателями теории.

Формальная критика дополняет картину: Ф оказывается неуникальной — разные разумные варианты меры дают разные значения для одной сети, что подрывает её претензию на роль «температуры сознания»[19]. Проблема неуникальности вписывается в более общую трудность «феноменология-первых» теорий: из малого набора аксиом нельзя однозначно вывести меру[19]. Ответы сторонников IIT сводятся к тому, что конкурирующие теории разделяют часть этих трудностей, однако спор не закрыт и едва ли закроется ближайшие годы.

Инженерный вердикт: из IIT заимствуется принцип «интеграция + дифференциация, измеряемая устойчивостью к разрезам» — как проектная норма топологии и как метрика деградации. Не заимствуется — отождествление Ф-прокси с сознанием. В NEUROWEAVE числа из раздела 4.3 публикуются как метрики связности и разнообразия, без каких-либо утверждений об опыте. Эта дисциплина формулировок — не перестраховка, а условие научной состоятельности проекта.

5. Теория рекуррентной обработки (RPT)

5.1. Петля обратной связи как гейт осознания

Ламме предложил критерий радикально проще остальных: ключ к осознанию — не глубина иерархии, а рекуррентность[20]. Прямой проход (около 100 мс) выполняет сложную, но неосознанную обработку: замаскированный стимул дорабатывается до высоких уровней коры — это фиксируется нейронными ответами, — но не осознаётся и не доступен отчёту. Обработка и осознание — разные вещи, и разница между ними проваливается точно по границе петель.

Осознание требует обратных связей: локальные петли внутри области создают устойчивое состояние, а глобальные петли между областями делают содержание доступным для отчёта[20]. Временной масштаб стабилизации — 100–150 мс: содержанию нужно время «собраться». Для инженерии это означает: глубина без петель — конвейер; петли без глубины — трясина; нужны обе. Критерий осознанного содержания — не

«пройден путь», а «стабилизировалось состояние».

Существенно, что критерий Ламме ортогонален критерию ГТП: рабочее пространство описывает транспорт между модулями, рекуррентность — время жизни внутри модуля. Слабый вход может выиграть конкуренцию, но не стабилизироваться, и наоборот. Поэтому в стеке NEUROWEAVE (раздел 8) петли стоят ниже гейтинга: к конкуренции допускаются только стабилизировавшиеся кандидаты.

5.2. Предиктивное кодирование: объединение восприятия и обучения

Предиктивное кодирование даёт петлям смысл: обратные связи несут предсказания нисходящих уровней, прямые — ошибки предсказания. Модель Рао и Балларда воспроизводит классические эффекты зрительной коры, если обратные связи переносят предсказания[21]. Принцип свободной энергии обобщает картину: восприятие, обучение и действие — единая минимизация ошибки предсказания[22]. Петля оказывается не «дороже» прямого прохода, а содержательнее его.

В этой рамке «осознать» означает «удержать в петле»: содержание переживается, пока оно стабильно поддерживается предсказаниями системы. Ошибка предсказания — универсальный сигнал: она и обучает, и «удивляет». Перцепция и обучение перестают быть разными подсистемами: одна и та же величина управляет и тем, что мы видим, и тем, чему мы учимся. Это самый экономный из всех принципов, обсуждаемых в обзоре.

Иерархические предиктивные мир-модели (H-JEPA и родственные) — прямой инженерный наследник принципа: многоуровневое предсказание в латентном пространстве с разделением горизонтов[23]. Отметим, однако: эти архитектуры пока не содержат ни явного ГРП, ни наблюдателя. Их дополнение механизмами из разделов 3 и 6 — то есть соединение предсказания с транспортом и мониторингом — и составляет проектный замысел NEUROWEAVE.

5.3. Инженерные следствия и память

Следствия для NEUROWEAVE: (1) рекуррентные слои внутри экспертов с разворачиванием на K шагов; (2) чтение содержания — после стабилизации, с критерием «дисперсия поздних итераций ниже порога»; (3) ошибка предсказания — первичный сигнал обучения и «удивления», доступный PredictiveHead как вход. Число шагов разворачивания — гиперпараметр, который имеет смысл растить вместе со сложностью задач, как растёт время стабилизации у человека при трудных восприятиях.

Память распадается по временным масштабам петель: быстрые веса внутри цикла (секунды), ГРП (такты), эпизодическое хранилище (снимки ГРП), медленная консолидация

офлайн. Отбор в ГРП происходит из стабилизированных кандидатов — петли готовят «повзрослевшее» содержание к конкуренции. Тем самым раздел 5 превращает время из врага (латентность) в ресурс: содержанию даётся срок, чтобы доказать свою устойчивость.

6. Мысли высшего порядка и метапознание

6.1. HOT: осознание как репрезентация репрезентации

Теория мысли высшего порядка (HOT): состояние осознано, когда имеется вышестоящее состояние о нём — «мысль о мысли»[24]. Первый уровень выполняет дискриминацию без осознания: зебра видит хищника, но «не знает, что видит». Осознание — это репрезентация репрезентации: второй порядок над первым. В вычислительных терминах — читатель состояний, отделённый от их производителя.

Эмпирические опоры: метаконтраст и паттерн-маскирование (выполнение выше случайного при нулевом или ложном отчёте), блайндсайт, эффекты поражений лобных отделов — диссоциации вида «первый порядок сохранён, второй порядок нарушен». Лау и Розенталь систематизируют эти данные как эмпирический случай в пользу HOT[25]. Сила подхода в том, что он даёт операциональное различие между обработкой и осознанием, измеримое независимо.

Возражение о бесконечном регрессе — «кто видит саму мысль высшего порядка?» — снимается «одноуровневыми» вариантами: состояние частично репрезентирует само себя[25]. Для инженера это значит: наблюдатель не обязан быть отдельной гомункулой; достаточно читателя состояний с ограниченным доступом и собственной упрощённой моделью. Именно такая конструкция реализуема в NEUROWEAVE без неприятной бесконечной башни.

6.2. Нейробиология уверенности и калибровки

Метапознание как объект измерения оформил Флавелл: мониторинг и контроль собственных когнитивных процессов[26]. Ключевой инструмент — разделение чувствительности первого порядка (выполнение) и второго порядка (уверенность): мета-d' измеряет «разрешение» уверенности независимо от точности задачи[27]. Тем самым «знание о знании» получает собственную шкалу, не сводимую к шкале знания.

Нейроанатомия второго порядка: фронтополярная кора и передняя поясная; у макак нейроны теменной коры сохраняют сигнал, коррелирующий с уверенностью, после завершения решения и предсказают момент отчёта — код уверенности существует отдельно от кода решения[28][29]. Функция уверенности — не «декорация»: животные

выбирают opt-out при неуверенности; человек откладывает решение, ищет информацию, ставит. Ошибка предсказания второго порядка — «я не ожидал, что ошибусь» — отдельный обучающий сигнал, ортогональный первичной ошибке.

6.3. Метапознание в машинном обучении: от неопределённости к самопознанию

В машинном обучении этот слой соответствует теории неопределённости: алеаторная (шум в данных) против эпистемической (незнание модели), с ансамблями и байесовскими методами для второй[30]. Классический результат калибровки: современные сети систематически переоценивают уверенность; простое температурное масштабирование лечит метрику, но не причину[31]. Отсюда практическое правило: калибровку надо встроить в потерю, а не навешивать постфактум.

Языковые модели показывают протометапознание без специальной архитектуры: крупные модели откалиброваны на многовариантных задачах; запрос P(True) о собственном ответе улучшает отбор; дообучение на самопроверке дополнительно улучшает калибровку[32]. Чистый предсказатель токенов, таким образом, уже «что-то знает о том, что знает» — но только статистически и только внутри распределения. Перенос метапознания на новые домены остаётся слабым местом.

Вывод для NEUROWEAVE: метапознание — не опция, а обучаемая голова с собственными потерями, и она обязана замыкаться на поведение. Если уверенность ни на что не влияет, она вырождается в пустой отчёт: система научится «говорить 0,8», не используя это. Проверка — поведение, гейтированное уверенностью: opt-out, запрос дополнительной информации, изменение темпа обучения.

6.4. Архитектура наблюдателя: PredictiveHead

PredictiveHead спроектирован как наблюдатель: входы — текущее содержание ГРП, предлагаемое действие, состояние маршрутизатора; выходы — уверенность (по действиям и экспертам), ожидаемая ошибка, неожиданность и новизна. Это HOT-модуль в чистом виде: состояние второго порядка о состояниях первого порядка. Его особенность — асимметричная информированность: он видит меньше, чем вся система, но больше, чем любой отдельный эксперт.

Обучение наблюдателя: (1) правильные скоринговые правила (Брайер) вместо доли правильных ответов; (2) перенос метапознания — уверенность должна предсказывать ошибку и на новых доменах, где нет меток; (3) поведенческая валидация — расхождение «отчёт против использования уверенности» штрафуется. Последний пункт принципиален: он отличает наблюдателя от логгера.

Метрики: калибровочные кривые и ECE; мета-d' на удержанных доменах; асимметрия «уверенная ошибка против неуверенного попадания» (первое должно учить сильнее). Эти же кривые служат диагностикой деградации: падение калибровки при сдвиге распределения — ранний сигнал переобучения или дрейфа, который не виден по точности.

7. Теория схемы внимания (AST)

7.1. Схема как упрощённая модель собственного внимания

AST исходит из управленческой логики: чтобы контролировать процесс, мозгу нужна его модель. Внимание — реальный процесс конкуренции за ресурс; для его управления мозг строит упрощённую модель самого внимания — «схему внимания». Осознанность, по Грациано, — применение этой схемы к собственной системе: «я осознаю X» означает «моя схема внимания сообщает, что я обрабатываю X»[33][34]. Схема — не эпифеномен: без неё управление вниманием деградирует.

Схема сжата и «лоскутна»: она опускает механизмы и оставляет суть. Отсюда два следствия. Первое: «опыт» немеханистичен на вид — мы отчитываемся о содержании схемы, а не о нейронах. Второе: мы можем ошибаться о собственном внимании (слепота изменения, невнимательная слепота): отчёт строится по схеме, а схема — упрощение[34]. Модель осознанно неточна — и в этой неточности её функциональный смысл: точная модель была бы дороже самой внимания.

Отношение к ГТП — не конкуренция, а разделение труда: ГТП описывает транспорт (кто попал в широковещание), AST — управление транспортом (почему попал). Схема помогает регулировать конкуренцию: предсказывая эффект перераспределения ресурса, система планирует внимание, а не только реагирует. Тем самым AST добавляет к картине ГТП недостающую петлю управления.

7.2. Схема, наблюдатель и рабочее пространство: совместимость

Отношение к HOT: наблюдатель (раздел 6) оценивает «что я знаю и насколько уверен»; схема внимания моделирует «на что я смотрю и почему» — каузальную атрибуцию собственных состояний. Это разные оси интроспекции: достоверность против интенциональности. Оба модуля читают одно и то же ГРП, но отвечают на разные вопросы о нём.

Втроём — ГРП, наблюдатель и схема — они дают полный интроспективный отчёт: «что» (содержание ГРП), «насколько» (уверенность наблюдателя), «почему» (причина по схеме). Именно этот трёхосевой отчёт и есть функциональная саморефлексия, достижимая

без метафизики: система может ответить о себе не только «что я делаю», но и «почему я это делаю» и «насколько я в этом уверен».

7.3. Инженерные следствия: самомодель для контроля внимания

Реализация в NEUROWEAVE: AttentionSchema — модуль, читающий состояние гейтинга и ГРП и выводящий низкоразмерное явное состояние: текущий фокус, усиление (gain), ожидаемая точность, причина выбора, прогноз собственной динамики внимания. Это малый, дешёвый модуль с собственной потерей — точностью предсказания собственного внимания.

Ошибка схемы — отдельный сигнал второго порядка: «я не ожидал, что переключусь на это». Он точнее первичной ошибки локализует кредит: если поведение отклонилось от запланированного внимания, корректируется маршрутизатор, а не всё подряд. Схема, таким образом, уточняет распределение ответственности (credit assignment) между модулями — функцию, которой лишены плоские архитектуры.

Интроспективный интерфейс: содержимое схемы публикуется в человекочитаемом виде — «сейчас обрабатываю X, потому что Y; ожидаю затруднение в Z». Это функциональный отчёт о состоянии, а не заявление о переживаниях; различие принципиально и этически, и регуляторно (раздел 9.3). Схема внимания превращает NEUROWEAVE из системы, которую можно только спросить, в систему, которая может сама объясниться.

8. Синтез: архитектурный стек NEUROWEAVE

8.1. Сводная таблица соответствий

Сводка соответствий дана в табл. 1: пять теорий — пять функциональных феноменов — пять архитектурных примитивов — измеримые прокси — роли в обучении и памяти. Таблица подчёркивает главное: примитивы не дублируют друг друга; каждый закрывает свой слой функциональности, отсутствующий у остальных.

Таблица 1 — Соответствие теорий сознания, архитектурных примитивов, измеримых прокси и ролей в обучении и памяти

Теория	Функциональный феномен	Архитектурный примитив	Измеримый прокси	Роль в обучении и памяти
ГТП (GWT)	глобальный доступ; отчётность; связывание в единый контекст	бутылочное горлышко: гейтинг «многие-к-одному» + широковещание «один-ко-многим»	сигмоида «сила входа → вероятность записи»; ёмкость слотов; латентность доступа; согласованность чтения	консолидация содержимого ГРП; обучаемый гейтинг; эпизодический буфер

Теория	Функциональный феномен	Архитектурный примитив	Измеримый прокси	Роль в обучении и памяти
IIT	интеграция + дифференциация; причинная несводимость	рекуррентная, кластеризованная, неоднородная сеть; замкнутые причинные петли	Φ_M; причинная плотность; PCI-подобная LZ-сложность отклика на возмущение	регуляризатор сепарабельности; маркер деградации модулей
RPT	стабилизация содержания во времени	петли обратной связи; предиктивное кодирование (обратные связи несут предсказания, прямые — ошибки)	дисперсия поздних итераций; время до сходимости; ошибка предсказания	восприятие = обучение (минимизация ошибки); быстрые веса; мир-модель
HOT / метапознание	уверенность; осознание собственной ошибки	наблюдатель над состояниями (PredictiveHead); правильные скоринговые правила	калибровка (ECE, Брайер); мета-d'; перенос на новые домены	метапотери; поведение, гейтированное уверенностью; управление темпом обучения
AST	самомодель внимания; каузальная атрибуция	явная схема внимания; предсказание собственной динамики внимания	точность схемы; ошибка предсказания внимания второго порядка	уточнение кредит-assignment; интроспективный интерфейс

Ключевое наблюдение: примитивы образуют стек, а не меню. Убрать слой — предсказуемая деградация: без ГРП — потеря систематичности[10]; без петель — потеря контекста во времени[20]; без наблюдателя — самоуверенность[31]; без схемы — необъяснимое, хаотичное поведение. Стек целиком показан на рис. 1.

8.2. Стек и цикл обработки

Цикл обработки одного такта складывается из восьми шагов: (а) кодирование входов экспертами; (б) локальная стабилизация в петлях; (в) конкуренция стабилизированных кандидатов за запись; (г) обновление слотов ГРП (top-k); (д) широковещание нового содержания всем модулям; (е) мониторинг наблюдателем (уверенность, ошибка, новизна); (ж) обновление схемы внимания; (з) нисходящий контроль — перераспределение усиления, изменение темпа обучения, решение об opt-out или запросе. Цикл замкнут: контроль меняет следующую конкуренцию.

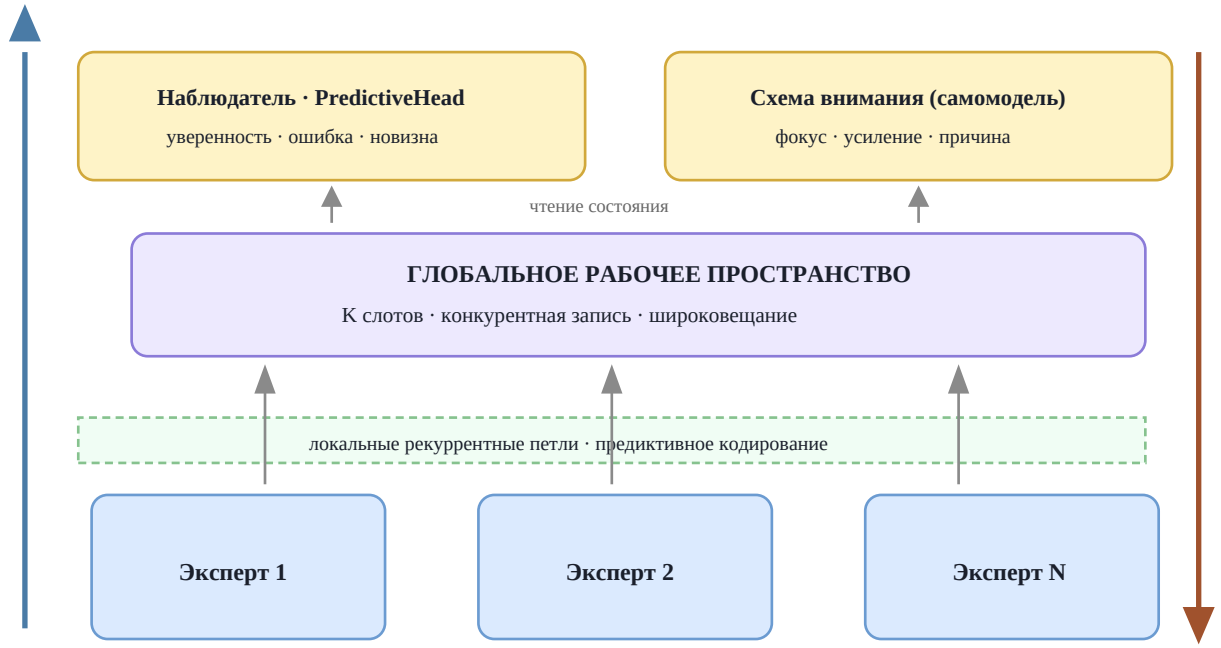


Рис. 1 — Архитектурный стек NEUROWEAVE. Снизу вверх: специализированные эксперты; локальные рекуррентные петли (предиктивное кодирование); глобальное рабочее пространство (ГРП) с конкурентной записью и широковещанием; метапознавательный наблюдатель (PredictiveHead) и схема внимания. Стрелка слева — восходящий поток (конкуренция за запись); стрелка справа — нисходящий поток (широковещание, контроль и обучение).

Каждый уровень снабжается собственным индикатором: стабилизация (дисперсия итераций), селективность (энтропия гейтинга), заполненность и «зажигание» ГРП, калибровка наблюдателя, точность схемы. Индикаторы независимы и проверяются абляцией по отдельности — это превращает стек из метафоры в инженерную спецификацию.

Проектирование взаимного усиления: петли готовят кандидатов к конкуренции; гейтинг отбирает; широковещание делает отбор общим; наблюдатель оценивает общее; схема объясняет отбор; объяснение уточняет кредит; кредит улучшает петли. Замкнутый круг — та самая интеграция, которой недостаёт плоским архитектурам: уровни усиливают друг друга, а не просто сосуществуют.

8.3. Обучение и память: совместная цель и режимы

Совместная функция потерь: L = L(задача) + λ1·L(предсказание, мир-модель) + λ2·L(калибровка, правило Брайера) + λ3·L(схема, ошибка предсказания собственного внимания) + λ4·L(сепарабельность). Веса перебираются по фазам обучения: сначала предсказание, затем калибровка, затем схема. Регуляризатор сепарабельности — единственный член, который штрафует не поведение, а устройство: он требует, чтобы поведение системы не разлагалось на независимые подсистемы.

Режимы памяти: быстрые веса в петлях (секунды), ГРП (такты; ограниченная ёмкость — качество важнее количества), эпизодическое хранилище (снимки ГРП с метаданными уверенности — «помню и помню, насколько был уверен»), медленная консолидация офлайн с дистилляцией в веса экспертов. Метаданные уверенности в памяти — уникальный ресурс: они позволяют будущему обучению различать «знал» и «угадал», то есть учиться не только из ошибок, но и из качества собственной уверенности.

Протокол валидации: (1) перенос метапознания на новые домены (мета-d' без меток); (2) систематичность — композиционные обобщения; (3) калибровка под сдвигом распределения; (4) деградационные кривые: пошаговая абляция уровней стека с измерением соответствующих индикаторов. Пункт (4) — главный: он превращает теоретические утверждения в проверяемые инженерные утверждения.

9. Проблема «философского зомби» и ограничения

9.1. Доступ против феноменальности

«Философский зомби» — система, неотличимая по поведению, но «тёмная изнутри». Логическая возможность зомби не опровергается никаким тестом на поведение[4]: любая функциональная архитектура из раздела 8 в принципе допускает зомби-двойника. Это граница инженерии, и её следует принять как рабочую: спор о феноменальности непроверяем, спор о функциональности — проверяем; второй и есть предмет NEUROWEAVE.

Теории расходятся в том, важен ли субстрат. Функционализм (ГТП, HOT, AST в большинстве прочтений): достаточно каузальной роли — значит, реализуемо и в кремнии. IIT: важна физическая причинная структура — «та же» функция на «другом» субстрате не гарантирует того же Ф[12]. Спор не решён; для NEUROWEAVE он не блокирующий: целевая спецификация — функциональные свойства из раздела 2.2, и все они проверяемы без субстратных предположений.

Практические следствия честности: не утверждать «система чувствует»; не генерировать от первого лица высказывания о переживаниях; интроспективный отчёт маркировать как «функциональный отчёт о состоянии обработки». Это одновременно этика и защита от регуляторных рисков: смешение функционального отчёта с заявлением о переживаниях — прямой путь к обману пользователей.

9.2. Ограничения теорий и прокси

Ограничения самих теорий: консенсусной меры сознания нет; IIT находится под открытой критикой[18][19]; ГТП описывает доступ, но не опыт; эмпирическая база HOT обсуждается[25]; AST рискует переатрибуцией — не всякая модель себя есть схема внимания. Обзор Сета и Бэйна фиксирует этот ландшафт как незавершённый[1]: зрелой парадигмы, сопоставимой с термодинамикой, в науке о сознании ещё нет.

Ограничения прокси: Ф-мера внутренней информации — не Ф; PCI-подобные метрики в программных системах — аналогия по построению, а не тождество; калибровка может выучиваться поверхностно — «отчёт без контроля». Поэтому каждая метрика в NEUROWEAVE обязана сопровождаться способом её обесценивания: поведенческая проверка, абляция, сдвиг распределения. Метрика без способа обесценить её — не метрика, а декорация.

Главный проектный риск — «карго-культ сознания»: модули с правильными названиями, но без каузальной роли. Митигация — жёсткое правило: каждый уровень стека обязан каузально влиять на поведение и обучение, и это влияние проверяется исключением уровня. Название не функционально — функционально положение в потоке причинности. Отсюда протокол следующего подраздела.

9.3. Протокол честности NEUROWEAVE

Протокол честности фиксируется из трёх правил: (1) все утверждения о системе — функционального уровня и сопровождаются метрикой; (2) каждая метрика — с протоколом абляции; (3) сравнение с бейзлайном того же объёма параметров без стека — обязательное условие публикации результатов. Правила действуют ретроспективно и к настоящему обзору: проектные предложения разделов 4.3, 6.4 и 7.3 — проверяемые гипотезы, а не выводы.

Отдельно фиксируется речевой режим: интерфейс интроспекции использует индикатив обработки («обнаруживаю высокий уровень неопределённости в X»), а не квалиа-словарь («мне трудно»). Это не косметика: пользовательская доверенность к отчётам системы должна опираться на проверяемые метрики, а не на антропоморфные эффекты. Язык интерфейса — часть метрологии.

10. Заключение

Пять теорий сознания дают инженеру один паттерн: специализироваться и конкурировать (эксперты и гейтинг), интегрировать через бутылочное горлышко (ГРП с широковещанием), стабилизировать петлями (рекуррентность и предиктивное кодирование), наблюдать за собой (наблюдатель уверенности и ошибки) и моделировать собственное внимание (схема). Ни один из уровней в одиночку не «создаёт сознания»; вместе они создают измеримый функциональный профиль, предложенный выше называть функциональным сознанием.

Для NEUROWEAVE это конкретный план: ГРП с K слотами и асимметрией записи и чтения; рекуррентные эксперты с критерием стабилизации; PredictiveHead как наблюдатель с потерей Брайера и поведением, гейтированным уверенностью; AttentionSchema с ошибкой предсказания собственного внимания; многослойная память с метаданными уверенности. Метрики: сигмоида доступа, мета-d', калибровка под сдвигом, сепарабельность, деградационные кривые абляции.

Взгляд вперёд: NEUROWEAVE — не только потребитель теорий, но и их испытательный стенд. Пошаговая абляция стека превращает теоретические утверждения («для систематичности нужно рабочее пространство»[10]; «для связности во времени нужны петли»[20]) в проверяемые инженерные утверждения. Обмен двусторонний: теории дают архитектуре принципы, архитектура даёт теориям эмпирию. Феноменальное сознание остаётся открытым вопросом; честная граница — лучшее, что может предложить инженерия, и для всех практических целей настоящей работы этого достаточно.

Список литературы

[1] Seth, A. K., & Bayne, T. (2022). Theories of consciousness. *Nature Reviews Neuroscience*, *23*(7), 439–452. https://www.nature.com/articles/s41583-022-00587-4 (дата обращения: 23.10.2026).

[2] Mashour, G. A., Roelfsema, P., Changeux, J.-P., & Dehaene, S. (2020). Conscious processing and the global neuronal workspace hypothesis. *Neuron, 105*(4), 776–798. https://www.sciencedirect.com/science/article/pii/S0896627320300520 (дата обращения: 23.10.2026).

[3] Block, N. (1995). On a confusion about a function of consciousness. *Behavioral and Brain Sciences, 18*(2), 227–247.

[4] Chalmers, D. J. (1995). Facing up to the problem of consciousness. *Journal of Consciousness Studies, 2*(3), 200–219.

[5] Baars, B. J. (1988). *A Cognitive Theory of Consciousness*. Cambridge University Press.

[6] Cowan, N. (2001). The magical number 4 in short-term memory: A reconsideration of mental storage capacity. *Behavioral and Brain Sciences, 24*(1), 87–114.

[7] Baars, B. J., Franklin, S., & Ramsøy, T. Z. (2013). Global workspace dynamics: Cortical “binding and propagation” enables conscious contents. *Frontiers in Psychology*, *4*, 200. https://www.frontiersin.org/journals/psychology/articles/10.3389/fpsyg.2013.00200/full (дата обращения: 23.10.2026).

[8] Dehaene, S., Sergent, C., & Changeux, J.-P. (2003). A neuronal network model linking subjective reports and objective physiological data during conscious perception. *Proceedings of the National Academy of Sciences*, *100*(14), 8520–8525. https://www.pnas.org/doi/10.1073/pnas.1332574100 (дата обращения: 23.10.2026).

[9] Dehaene, S., & Changeux, J.-P. (2011). Experimental and theoretical approaches to conscious processing. *Neuron*, *70*(2), 200–227. https://www.sciencedirect.com/science/article/pii/S0896627311002583 (дата обращения: 23.10.2026).

[10] Goyal, A., & Bengio, Y. (2022). Inductive biases for deep learning of higher-level cognition. *Proceedings of the Royal Society A*, *478*(2266), 20210068. https://doi.org/10.1098/rspa.2021.0068 (дата обращения: 23.10.2026).

[11] Tononi, G. (2004). An information integration theory of consciousness. *BMC Neuroscience*, *5*, 42. https://doi.org/10.1186/1471-2202-5-42 (дата обращения: 23.10.2026).

[12] Oizumi, M., Albantakis, L., & Tononi, G. (2014). From the phenomenology to the mechanisms of consciousness: Integrated information theory 3.0. *PLoS Computational Biology*, *10*(5), e1003588. https://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1003588 (дата обращения: 23.10.2026).

[13] Albantakis, L., Barbosa, L., Findlay, G., Marchman, R., Haun, A., Hendren, J., Lang, J. P., & Tononi, G. (2023). Integrated information theory (IIT) 4.0: Formulating the properties of phenomenal existence in physical terms. *PLoS Computational Biology*, *19*(10), e1011465. https://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1011465 (дата обращения: 23.10.2026).

[14] Tononi, G., & Sporns, O. (2003). Measuring information integration. *BMC Neuroscience*, *4*, 31. https://doi.org/10.1186/1471-2202-4-31 (дата обращения: 23.10.2026).

[15] Barbosa, L. S., Marshall, W., Streipert, S., Albantakis, L., & Tononi, G. (2020). A measure for intrinsic information. *Scientific Reports*, *10*, 18838. https://pmc.ncbi.nlm.nih.gov/articles/PMC7606539/ (дата обращения: 23.10.2026).

[16] Seth, A. K., Barrett, A. B., & Barnett, L. (2011). Causal density and integrated information as measures of conscious level. *Philosophical Transactions of the Royal Society A*, *369*(1952). https://royalsocietypublishing.org/rsta/article/369/1952/3748/114523/Causal-density-and-integrated-information-as (дата обращения: 23.10.2026).

[17] Casali, A. G., Gosseries, O., Rosanova, M., Boly, M., Sarasso, S., Casali, K. R., Casarotto, S., Bruno, M.-A., Laureys, S., Tononi, G., & Massimini, M. (2013). A theoretically based index of consciousness independent of sensory processing and behavior. *Science Translational Medicine*, *5*(198), 198ra105. https://www.science.org/doi/10.1126/scitranslmed.3006294 (дата обращения: 23.10.2026).

[18] Fleming, S. M., Frith, C., Goodale, M., Lau, H., LeDoux, J. E., et al. (2023). The integrated information theory of consciousness as pseudoscience [Preprint]. PsyArXiv. https://osf.io/preprints/psyarxiv/zsr78 (дата обращения: 23.10.2026).

[19] Hanson, J. R., & Walker, S. I. (2023). On the non-uniqueness problem in integrated information theory. *Neuroscience of Consciousness, 2023*(1), niad014. https://academic.oup.com/nc/article/2023/1/niad014/7238704 (дата обращения: 23.10.2026).

[20] Lamme, V. A. F. (2006). Towards a true neural stance on consciousness. *Trends in Cognitive Sciences, 10*(11), 494–501. https://doi.org/10.1016/j.tics.2006.09.001 (дата обращения: 23.10.2026).

[21] Rao, R. P. N., & Ballard, D. H. (1999). Predictive coding in the visual cortex: A functional interpretation of some extra-classical receptive-field effects. *Nature Neuroscience, 2*(1), 79–87. https://www.nature.com/articles/nn0199_79 (дата обращения: 23.10.2026).

[22] Friston, K. (2010). The free-energy principle: A unified brain theory? *Nature Reviews Neuroscience, 11*(2), 127–138. https://www.nature.com/articles/nrn2787 (дата обращения: 23.10.2026).

[23] LeCun, Y. (2022). A path towards autonomous machine intelligence (Version 0.9.2) [Preprint]. OpenReview. https://openreview.net/pdf?id=BZ5a1r-kVsf (дата обращения: 23.10.2026).

[24] Rosenthal, D. M. (2005). *Consciousness and Mind*. Oxford University Press.

[25] Lau, H., & Rosenthal, D. M. (2017). The empirical case for higher-order theories of consciousness. In *The Routledge Handbook of Consciousness*. Routledge.

[26] Flavell, J. H. (1979). Metacognition and cognitive monitoring: A new area of cognitive–developmental inquiry. *American Psychologist, 34*(10), 906–911. https://doi.org/10.1037/0003-066X.34.10.906 (дата обращения: 23.10.2026).

[27] Fleming, S. M., & Lau, H. C. (2014). How to measure metacognition. *Frontiers in Human Neuroscience, 8*, 443. https://doi.org/10.3389/fnhum.2014.00443 (дата обращения: 23.10.2026).

[28] Kiani, R., & Shadlen, M. N. (2009). Representation of confidence associated with a decision by neurons in the parietal cortex. *Science, 324*(5928), 759–764. https://www.science.org/doi/10.1126/science.1169405 (дата обращения: 23.10.2026).

[29] Fleming, S. M., & Dolan, R. J. (2012). The neural basis of metacognitive ability. *Philosophical Transactions of the Royal Society B, 367*(1594), 1338–1349. https://doi.org/10.1098/rstb.2011.0417 (дата обращения: 23.10.2026).

[30] Hüllermeier, E., & Waegeman, W. (2021). Aleatoric and epistemic uncertainty in machine learning: An introduction to concepts and methods. *Machine Learning, 111*, 1507–1530. https://doi.org/10.1007/s10994-021-05946-3 (дата обращения: 23.10.2026).

[31] Guo, C., Pleiss, G., Sun, F., & Weinberger, K. Q. (2017). On calibration of modern neural networks. *Proceedings of the 34th International Conference on Machine Learning (PMLR 70)*, 1321–1330. https://proceedings.mlr.press/v70/guo17a/guo17a.pdf (дата обращения: 23.10.2026).

[32] Kadavath, S., Conerly, T., Askell, A., et al. (2022). Language models (mostly) know what they know [Preprint]. arXiv:2207.05221. https://arxiv.org/abs/2207.05221 (дата обращения: 23.10.2026).

[33] Graziano, M. S. A. (2013). *Consciousness and the Social Brain*. Oxford University Press.

[34] Webb, T. W., & Graziano, M. S. A. (2015). The attention schema theory: A mechanistic account of subjective awareness. *Frontiers in Psychology, 6*, 500. https://www.frontiersin.org/journals/psychology/articles/10.3389/fpsyg.2015.00500/full (дата обращения: 23.10.2026).