Математические основания вычислений в мозге

От активных дендритов к критической динамике: уравнения, переменные состояния, правила обучения и реализации на PyTorch

Super Z

Super Z — Отдел исследований искусственного интеллекта (AI Research Division)

Корреспонденция: Super Z (через сессию платформы Z.ai). Все источники проверены 23.10.2026.

Дата подачи: 23 октября 2026 г.

Аннотация

Какие уравнения описывают вычисления в мозге — не то, что он делает, а как он это делает? В работе систематически извлечены пять фундаментальных математических формализмов теоретической нейробиологии, пригодных для прямого переноса в код: (1) дендритные вычисления — кабельное уравнение, NMDA-спайки и кальциевые плато, двухслойная модель пирамидного нейрона и трёхфакторное правило Урбанчика–Сенна; (2) предиктивное кодирование и вариационная свободная энергия Фристона, Рао–Балларда и Уиттингтона–Богача; (3) теория эффективного кодирования — сбалансированные сети, разрежённое кодирование и независимые компоненты; (4) аттракторная динамика — сети Хопфилда, современные плотные ассоциативные памяти, непрерывные аттракторы и хаотическая блуждающая динамика; (5) теория критичности — ветвящиеся процессы и нейрональные лавины. Для каждого механизма выдержан единый формат: базовое уравнение, переменные состояния (что именно хранит нейрон и синапс), численный метод решения, связь с обучением (локальные правила против глобального градиента), вычислительная сложность и возможности её факторизации, а также проверяемые ссылки на первоисточники 1954–2024 гг. Показано, что пять формализмов складываются в единый вычислительный «стек»: дендриты — локальный субстрат, свободная энергия — цель обучения, эффективное кодирование — формат представления, аттракторы — память и навигация, критичность — режим максимальной динамической чувствительности. Для всех пяти механизмов приведён работоспособный псевдокод на PyTorch, готовый к адаптации.

Ключевые слова: дендритные вычисления; предиктивное кодирование; свободная энергия; эффективное кодирование; аттракторные сети; критичность; локальное обучение; PyTorch

Содержание

1. Введение 4

2. Дендритные вычисления: биофизика, двухслойность, локальное обучение 5

2.1. Кабельное уравнение и пассивный каркас 5

2.2. Активные нелинейности: NMDA-спайки и кальциевые плато 6

2.3. Двухслойная модель пирамидного нейрона 7

2.4. Дендриты как локус иерархического предиктивного кодирования 8

2.5. Трёхфакторное правило Урбанчика–Сенна и микросхема Сакраменто 9

2.6. Сводка механизма и псевдокод PyTorch 11

3. Предиктивное кодирование и принцип свободной энергии 12

3.1. Вариационная свободная энергия 12

3.2. Иерархическое предиктивное кодирование Рао–Балларда 13

3.3. Локальные правила, эквивалентность backprop и дендритная реализация . . 14

3.4. Сводка механизма и псевдокод PyTorch 15

4. Теория эффективного кодирования 17

4.1. Сбалансированные сети и хаотическая динамика 17

4.2. Разрежённое кодирование: Olshausen–Field и локальное соревнование 18

4.3. Независимые компоненты: infomax и естественный градиент 19

4.4. Сводка механизма и псевдокод PyTorch 20

5. Аттракторные сети и динамика 21

5.1. Сети Хопфилда: память как энергетический ландшафт 21

5.2. Современные ассоциативные памяти: экспоненциальная ёмкость 22

5.3. Непрерывные аттракторы: интеграторы, кольца, карты 23

5.4. Хаотическая блуждающая динамика (itinerancy) 24

5.5. Сводка механизма и псевдокод PyTorch 24

6. Теория критичности 26

6.1. Ветвящиеся процессы и нейрональные лавины 26

6.2. Оценка параметра ветвления и режимы реальной коры 27

6.3. Вычислительные выгоды критичности 27

6.4. Критика и границы применимости 28
6.5. Сводка механизма и псевдокод PyTorch 29

7. Синтез: пять формализмов как единый вычислительный стек 30

8. Ограничения и контраргументы 32

9. Заключение и следствия 32

Литература 33

1. Введение

Человеческий мозг содержит порядка 86 миллиардов нейронов и порядка 10^{14} синапсов [1], а весь этот вычислительный конгломерат потребляет примерно 20 Вт — мощность слабой лампочки накаливания [2]. На этом скромном бюджете выполняются задачи, которые современные глубокие сети решают ценой киловатт и мегаватт: распознавание сцены за 150 миллисекунд, навигация, планирование и непрерывное обучение на потоке данных без эпох и датасетов. При этом отдельные нейроны — устройства с шумом, частотой разрядов около 10 Гц и латентностью миллисекунды, казалось бы, лишённые ресурсов для «серьёзной» математики. Парадокс разрешается только одним способом: мозг не имитирует универсальную машину фон Неймана, а реализует вычисления физикой собственной среды — градиентами напряжения, регенеративными нелинейностями мембраны, балансом возбуждения и торможения и коллективной динамикой больших сетей.

Нейронаука накопила колоссальный корпус данных о том, что делает мозг: какие структуры активны при каких задачах, какими свойствами обладают рецептивные поля, где локализована рабочая память. Но инженеру, желающему построить систему, обучающуюся как мозг, требуются уравнения: какие переменные состояния хранит нейрон, по какому закону они эволюционируют, как из динамики рождается правило обучения и какова цена вычисления. Настоящий обзор адресован именно этому дефициту. Из обширной литературы по теоретической нейробиологии извлечены математические формализмы, каждый из которых удовлетворяет трём критериям: (а) он описывает базовый вычислительный механизм, а не феноменологию; (б) он записан явными уравнениями, допускающими численное решение; (в) он порождает локальное правило обучения, реализуемое в биологически правдоподобной сети.

Отобранные формализмы выстраиваются в пять уровней, которые в совокупности образуют «стек» мозговых вычислений. Активные дендриты — субстрат локальных нелинейных подвычислений, превращающих каждый нейрон в двухслойную машину вывода (раздел 2). Предиктивное кодирование и принцип свободной энергии — глобальная целевая функция, спускающаяся до синапсов в форме локально вычислимых ошибок предсказания (раздел 3). Теория эффективного кодирования определяет формат представления:

сбалансированные возбуждающе-тормозные сети реализуют статистически оптимальные коды (раздел 4). Аттракторная динамика даёт механизм памяти и пространственной навигации — от дискретных энергетических ландшафтов Хопфилда до непрерывных аттракторов гиппокампальной системы (раздел 5). Наконец, теория критичности описывает режим работы сети в целом — балансирование на грани фазового перехода, максимизирующее динамический диапазон и гибкость вычислений (раздел 6).

Методологически каждый механизм описан в едином формате, удобном для превращения в код: **уравнение** — точная форма из первоисточника; **переменные** — состояние, которое обязан хранить нейрон или синапс; **численный метод** — явный или экспоненциальный Эйлер, метод Рунге–Кутты, аналитическая редукция или итеративный цикл вывода; **связь с обучением** — локальное правило, STDP-совместимость или эквивалентность градиенту; **сложность** — стоимость шага в терминах O(·) и пути её факторизации; **ссылки** — проверенные первоисточники с датами обращения. В конце каждого раздела механизм зафиксирован в сводной карточке и сопровождён компактным, но работоспособным псевдокодом на PyTorch, реализующим динамику и правило обучения «в лоб». Раздел 7 сопоставляет механизмы в единой таблице и показывает, как они комбинируются; раздел 8 суммирует ограничения и контраргументы; раздел 9 формулирует практические следствия для NeuroAI-инженерии.

2. Дендритные вычисления: биофизика, двухслойность, локальное обучение

2.1. Кабельное уравнение и пассивный каркас

Отправной точкой дендритной математики служит пассивное кабельное уравнение, выводимое из закона Ома и закона сохранения заряда для участка мембраны [11]. Оно связывает мембранный потенциал V(x,t) вдоль дендрита с его пассивными свойствами — удельным сопротивлением мембраны r_m, продольным сопротивлением r_a и ёмкостью c_m:

$$\lambda^2 \frac{\partial^2 V}{\partial x^2} = \tau \frac{\partial V}{\partial t} + V - r_m\, i_e(x,t), \qquad \lambda = \sqrt{r_m / r_a}, \;\; \tau = r_m c_m$$ Уравнение (1)

Здесь λ — электротоническая длина постоянная, τ — мембранная постоянная времени, $i_e(x,t)$ — внешний синаптический ток на единицу длины. Уже пассивный дендрит выполняет вычисления: он затухает как $e^{-x/\lambda}$ и задерживает сигналы, так что различие времени прибытия двух входов по разным путям становится вычислимой величиной на соме. Линейность уравнения (1) позволяет аналитически вычислять передаточные функции между любыми точками арбора, чем и пользуется всё современное компартментное моделирование.

Численно дендритную арборизацию режут на N_c изопотенциальных компартментов; возникающая система линейных уравнений имеет трёхдиагональную структуру, и неявный метод Хинса решает её за $O(N_c)$ операций на шаг интегрирования. Для быстрых симуляций удобен экспоненциальный Эйлер, точный для линейной утечки при любом шаге: $V(t+\Delta t) = V_\infty + (V(t) - V_\infty)\cdot e^{-\Delta t/\tau}$, где V_∞ — стационарное значение при фиксированных токах. Нейрону достаточно хранить вектор компартментных потенциалов $\{V_i\}$ и множество проводимостей; синапсу — не нужно ничего, кроме собственного веса. Сложность шага одного нейрона — $O(N_c)$, сети из M нейронов — $O(M\cdot N_c)$; редукция арбора к двум компартментам (раздел 2.5) снижает стоимость нейрона до O(1) и является стандартным приближением для сетевого моделирования.

2.2. Активные нелинейности: NMDA-спайки и кальциевые плато

Пассивный каркас переворачивается активными проводимостями, и первая из них — NMDA-рецептор с его знаменитой вольт-зависимой блокировкой ионного поры внеклеточным магнием. Количественное описание Jahre–Стивенса [10] даёт ток NMDA-канала как функцию локального потенциала V и доли открытых рецепторов s:

$$I_{NMDA}(V) = \bar{g}_{NMDA}\, s \frac{(V - E_{NMDA})}{(1 + [Mg^{2+}]/3.57)\, e^{-0.062\,V}} \qquad \text{Уравнение (2)}$$

Ключевая особенность — экспоненциальная разблокировка поры при деполяризации: рост V увеличивает проводимость, а рост проводимости ещё сильнее деполяризует участок. Когда петлевое усиление этой положительной обратной связи превышает единицу, локальная деполяризация ~5–10 мВ запускает регенеративное событие — NMDA-спайк: плато амплитудой 40–50 мВ длительностью десятки

миллисекунд, зарегистрированное в базальных дендритах корковых пирамидных нейронов [9]. Именно так дендритная ветвь «решает», когда генерировать локальный спайк: она непрерывно интегрирует локальный синаптический вклад, и как только регенеративный порог превышен, событие разворачивается автономно, почти не завися от сомы.

Второй регенеративный механизм — кальциевое плато апикального пучка (Ca-спайк), впервые показанный Ларкумом с соавторами [7]: волна деполяризации, пришедшая из сомы (bAP), плюс сильный дистальный возбуждающий вход открывают Ca-каналы, и генерируется плато, интегрирующееся в соматический пачечный разряд. Более того, кальциевая электрогенезия наступает при критической частоте обратных спайков [8] — нейрон тем самым измеряет частоту собственного выхода и сообщает её дистальному дендриту. Время прибытия bAP в дендрит несёт информацию о моменте соматического спайка, и, как показали Мэги и Джонстон [6], совпадение bAP с предшествующим EPSP даёт ассоциативный сигнал для хеббовской пластичности — механизм STDP обретает биофизическую локализацию именно в дендрите [5].

Итак, переменные состояния активного дендрита: локальный потенциал V(x,t), фракция активных NMDA-рецепторов s (с собственной кинетикой активации/деактивации десятки–сотни мс), внутриклеточная концентрация кальция $[Ca^{2+}]$ как медленный след плато, и флаг регенеративного события. Численно связка (1)–(2) — это жёсткая нелинейная ODE-система; на практике используют явный Эйлер с шагом 0,1–0,25 мс или экспоненциальный Эйлер по утечке с явным обновлением активных токов. Локальный порог спайка не задаётся константой, а возникает из условия петлевого усиления $g_{NMDA}(V)\cdot R_{лок} > 1$ — то есть зависит от локального входного сопротивления ветви и числа открытых каналов, что и делает дендритные вычисления контекстно-зависимыми.

2.3. Двухслойная модель пирамидного нейрона

Какую вычислительную архитектуру задаёт вся эта биофизика? Пойраци и Мел показали, что пирамидный нейрон с нелинейными дендритами эквивалентен двухслойной нейронной сети [12, 13]: сома — выходной суммирующий слой, а множество электрически

квазинезависимых дендритных ветвей — скрытый слой пороговых субъединиц. Формально вход-выход нейрона записывается как

$$y = g_S\left(\sum_{j=1}^{m} w_j^S \, g_D\left(\sum_{k=1}^{n} w_{jk}^D \, x_k\right)\right) \qquad \text{Уравнение (3)}$$

где g_D — сатурирующая нелинейность отдельной ветви (грубо — функция локального NMDA/Ca-порога из раздела 2.2), g_S — соматическая передаточная функция, w^D — синаптические веса ветвей, w^S — веса дистрибуции ветвей на сому. Каждый нейрон, таким образом, — это перцептрон с одним скрытым слоем, и вычислительная ёмкость нейронной ткани пропорциональна не числу нейронов, а числу дендритных субъединиц: в [12] показано, что ёмкость ассоциативной памяти на таком нейроне растёт на порядки по сравнению с точечным нейроном, а правило структурной пластичности — случайная проба синапса плюс стабилизация коррелированных — способно её заполнить.

Лондон и Хойссер систематизировали «операции» такого нейрона [11]: линейная фильтрация и затухание, обнаружение совпадений в окне миллисекунд, локальное пороговое логическое «И» для входов на одной ветви, инверсная логика «И-НЕ» через тормозные входы ветви, а также направленное затухание с возможностью скрыть «несвоевременный» вход. Сложность прямого прохода — $O(N_{син})$ на нейрон, где $N_{син}$ — число синапсов, с тривиальной параллелизацией по ветвям: m субъединиц считаются независимо ($O(N_{син}/m)$ каждая), и лишь затем суммируются на соме — естественная факторизация, которую стоит воспроизводить и в коде.

2.4. Дендриты как локус иерархического предиктивного кодирования

Ключевая анатомическая асимметрия пирамидного нейрона идеально ложится на схему предиктивного кодирования (детально — раздел 3): базальные дендриты принимают восходящий (feedforward) вход снизу иерархии, а апикальный пучок получает нисходящий (feedback) контекст от вышележащих областей и таламуса. Ларкум аргументировал [14], что совпадение нисходящего сигнала с восходящим — как раз то, что реализуется Ca-плато в апикальном пучке, — образует клеточный механизм корковых ассоциаций: кортекс вычисляет их на уровне отдельных нейронов, а не только на уровне

сетей. В терминах предиктивного кодирования кальциевое плато — это физиологический маркер «встречи» предсказания и данных: сильный апикальный вход при отсутствии подтверждения снизу рождает плато и последующий пачечный разряд, который «выкрикивает» непредсказанное — ошибку — вверх по иерархии.

Формализация этой идеи выполнена Сакраменто, Сенном, Бенджио и Костой [17] в виде микросхемы из пирамидных клеток и интернейронов: апикальная дендритная композиция вычисляет разность между нисходящим предсказанием и локально реконструированным ожиданием, и именно эта разность служит сигналом ошибки для пластичности базальных синапсов. Схема Урбанчика–Сенна (следующий подраздел) даёт этому двухкомпартментную алгебру; Сакраменто расширяет её на глубокую иерархию и аналитически показывает, что обновления весов воспроизводят алгоритм обратного распространения ошибки — при полностью локальных сигналах. Параллельно Гергюев, Лилликрэп и Ричардс [18] продемонстрировали, что сети с изолированными базальным и апикальным компартментами обучаются глубокому представлению с локальным правилом и обратной связью без точной симметрии весов. Связь дендритов с иерархическим предиктивным кодированием (hPC) — центральный пример того, как один субклеточный механизм реализует сразу и вычисление, и обучение.

2.5. Трёхфакторное правило Урбанчика–Сенна и микросхема Сакраменто

Урбанчик и Сенн предложили минимальную компартментную модель, в которой дендрит «прогнозирует» соматическую активность [16]. Дендритный и соматический потенциалы эволюционируют согласно системе (здесь и далее — формы, близкие к [16]):

$$C_m \frac{dV_D}{dt} = -g_L\,(V_D - E_L) + I_D(t) + \sum_i w_i\, x_i(t) \qquad \text{Уравнение (4)}$$

$$C_m \frac{dV_S}{dt} = -g_L\,(V_S - E_L) + g_D\,(V_D - V_S) + I_S(t) \qquad \text{Уравнение (5)}$$

где C_m — ёмкость, g_L — утечка, E_L — потенциал покоя, g_D — проводимость связи дендрит→сома, I_S — ток, поступающий прямо на сому (например, «учитель»), I_D — прочий дендритный вход. Дендритная часть моделирует интеграцию синапсов w_i с преактивностью $x_i(t)$.

Ключевая величина — соответствующий потенциал V^*_D, то есть потенциал, который дендрит «обещает» соме в отсутствие внешних соматических токов:

$$V_D^* = \frac{g_L E_L + g_D V_D}{g_L + g_D}$$ Уравнение (6)

Соматическая частота задаётся гладкой передаточной функцией $\varphi(V_S)$ (например, сигмоидой с порогом θ и крутизной β). Обучение минимизирует расхождение между фактической соматической частотой $S(t)$ (спайковый поезд учителя или собственная активность) и частотой $\varphi(V^*_D)$, которую дендрит пророчил бы сам. Градиентный спуск по весам даёт трёхфакторное правило:

$$\Delta w_i = \eta \left[S(t) - \phi(V_D^*) \right] \frac{\partial V_D}{\partial w_i}$$ Уравнение (7)

Первый фактор $S(t) - \varphi(V^*_D)$ — «ошибка»: расхождение между реальной соматической активностью и дендритным прогнозом, она доступна синапсу как локальная волна соматической деполяризации (bAP из раздела 2.2). Второй фактор $\partial V_D/\partial w_i \propto x_i$ — вклад данного синапса, тождественный пресинаптической активности с локальным коэффициентом. Третьим фактором служит производная локальной нелинейности ветви. Правило, таким образом, локально: синапсу нужны только собственные след x_i, локальный дендритный потенциал и глобально «разлитая» по нейрону соматическая ошибка. В зависимости от природы I_S то же правило реализует контролируемое обучение (учитель в I_S), неконтролируемое ($I_S=0$, самопрогноз) и обучение с подкреплением (награда модулирует скорость η) [16].

Микросхема Сакраменто с соавторами [17] поднимает это правило до глубокой иерархии. В каждом пирамидном нейроне выделяются соматический, базальный и апикальный компартменты; апикальный вычисляет сигнал ошибки, получая нисходящее возбуждение W^{fb} и локальное торможение от интернейрона, который «изымает» предсказуемую часть обратной связи. Представительная форма архитектуры:

$$V_l^A \approx \rho\left(W_l^{fb} r_{l+1} - W_l^I r_l^I\right)$$

$$\Delta W_l^{basal} \propto \delta_l^A \cdot r_{l-1} \cdot \phi'\left(V_l^S\right), \qquad \delta_l^A = \rho(V_l^A) - \rho(\hat{V}_l^A)$$ Уравнение (8)

Пластичность базальных синапсов пропорциональна произведению апикальной ошибки δ^A, пресинаптической активности нижнего уровня

r_{l-1} и производной соматической активации. Авторы показывают аналитически, что в многослойной сети стационарные точки этих локальных обновлений совпадают с обновлениями backpropagation, а на задачах регрессии и классификации схема работает наравне с градиентным обучением [17]. По численной части: систему (4), (5) интегрируют явным или экспоненциальным Эйлером с шагом 0,1–1 мс; итерации до стационарности занимают десятки миллисекунд модельного времени — на два порядка быстрее биологического времени обучения. По хранению: нейрон держит V_D, V_S, V^*_D, синапс — w_i и след x_i. Сложность: обновление одного синапса O(1); сети из N нейронов с полной связностью — $O(N^2)$ на шаг, что факторизуется до O(N·K) при K эффективных дендритных ветвях на нейрон.

2.6. Сводка механизма и псевдокод PyTorch

Параметры формализма зафиксированы в Таблице 1; реализация динамики и обучения — в Листинге 1.

Таблица 1. Сводная карточка: дендритные вычисления

Уравнения	(1)–(8): кабельное уравнение; NMDA-ток Jahre–Стивенса; двухслойная модель (3); двухкомпартментная динамика (4)–(6); трёхфакторное правило (7); апикальная ошибка Сакраменто (8)
Переменные состояния	V_D, V_S, V^*_D; локальные V(x,t), s_{NMDA}, $[Ca^{2+}]$; в синапсе: w_i, след x_i
Численный метод	компартменты + неявный метод Хинса $O(N_c)$; явный/экспоненциальный Эйлер с шагом 0,1–1 мс; аналитическая редукция к 2 компартментам
Связь с обучением	трёхфакторное локальное правило (7); STDP-совместимость через bAP+EPSP совпадения; эквивалентность backprop в иерархии [17]
Сложность	O(1) на синапс; $O(N^2)$ на сеть; факторизация по K дендритным ветвям → O(N·K)
Ключевые ссылки	[5]–[18]: Stuart–Sakmann; Magee–Johnston; Larkum 1999 (Nature, PNAS); Schiller; Jahr–Stevens; London–Häusser; Poirazi–Mel; Larkum 2013; Urbanczik–Senn; Sacramento; Guergiuev

Листинг 1. Двухкомпартментный нейрон с правилом Урбанчика–Сенна (PyTorch)

```
import torch

class TwoCompartmentNeuron(torch.nn.Module):
    """Двухкомпартментная модель (ур. 4-7): дендрит прогнозирует сому.
    Динамика — явный Эйлер; пластичность — трёхфакторное правило (7)."""
    def __init__(self, n_in, dt=1e-3):
        super().__init__()
        self.dt = dt
        self.Cm, self.gL, self.EL = 1.0, 0.05, -70.0   # единицы СГС упрощены
        self.gD = 0.1                                  # связь dendrite -> soma
```

```
        self.phi_max, self.beta, self.theta = 100.0, 1.0, -50.0
        self.w = torch.nn.Parameter(0.01 * torch.randn(n_in))
        self.register_buffer('V_D', torch.tensor(self.EL))
        self.register_buffer('V_S', torch.tensor(self.EL))

    def phi(self, V):                                  # соматический gain
        return self.phi_max / (1.0 + torch.exp(-self.beta * (V - self.theta)))

    def step(self, x, I_S=0.0):
        """Прямой шаг: интеграция (4)-(5) явным Эйлером."""
        I_D = (self.w * x).sum()                       # синаптический вход дендрита
        self.V_D = self.V_D + self.dt / self.Cm * (
            -self.gL * (self.V_D - self.EL) + I_D)
        self.V_S = self.V_S + self.dt / self.Cm * (
            -self.gL * (self.V_S - self.EL) + self.gD * (self.V_D - self.V_S) + I_S)
        return self.phi(self.V_S)

    def plasticity(self, x, S_t, eta=1e-3):
        """Правило (7):  dw_i = eta * [S - phi(V*_D)] * dV_D/dw_i.
        dV_D/dw_i ~ x_i*dt/Cm — вклад синапса i в дендритный потенциал."""
        V_star = (self.gL * self.EL + self.gD * self.V_D) / (self.gL + self.gD)  # (6)
        err = S_t - self.phi(V_star)                   # постсинаптическая 'ошибка'
        dV_dw = x * self.dt / self.Cm                  # локальный градиент ветви
        with torch.no_grad():
            self.w += eta * err * dV_dw                # три фактора, все локальны
        return err
```

Листинг 1 содержит полный минимум для нейроморфного прототипа: динамику (4)–(5), вычисление соответствующего потенциала (6) и обновление весов (7). Расширение до микросхемы Сакраменто сводится к добавлению апикального компартмента с интернейроном-вычитателем и к замене фактора ошибки на δ^{A} из (8); публичные реализации на GeNN существуют и поддерживают эксперименты с латентным равновесием и изучением обратных весов [67]. Для массовых симуляций NEST и Arbor поставляют готовые компартментные модели и правило Урбанчика–Сенна в виде встроенной пластичности.

3. Предиктивное кодирование и принцип свободной энергии

3.1. Вариационная свободная энергия

Принцип свободной энергии Фристона — это глобальная целевая функция, из которой выводятся и восприятие, и обучение [20, 22]. Мозг постулируется как машина аппроксимации байесовского вывода: он не вычисляет точно posterior $p(\theta|o)$ по причинам θ при данных o, а подбирает распределение $q(\theta)$, минимизируя вариационную свободную энергию:

$$F(q(\theta)) = \mathbb{E}_{q(\theta)}[\ln q(\theta) - \ln p(\mathbf{o}, \theta)] \geq -\ln p(\mathbf{o})$$ Уравнение (9)

Первое слагаемое — ожидаемая «неточность» генеративной модели p(o,θ), второе — расхождение (Кульбак–Лейблер) между q и точным апостериорным распределением. Поскольку F ограничивает сверху сюрприз −ln p(o), минимизация свободной энергии одновременно улучшает и предсказание данных, и приближение к байесовскому выводу. Восприятие трактуется как оптимизация достаточной статистики μ распределения q, а обучение — как оптимизация параметров θ самой генеративной модели [22]:

$$\dot{\mu} = -\kappa \frac{\partial F}{\partial \mu} \qquad \Delta\theta = -\eta \frac{\partial F}{\partial \theta}$$ Уравнение (10)

Константа к — скорость градиентного спуска по μ; η — скорость обучения. В динамической формулировке Фристона (обобщённые координаты состояний) градиент дополняется оператором временного сдвига Dμ, что в пределе даёт фильтрацию Калмана и обобщает её на нелинейные иерархии [21]. С точки зрения хранения: нейрон уровня хранит оценку причин μ (например, мембранный потенциал как суррогат), ошибку ε, а синапсы — параметры θ с точностью до локального обновления. Численно восприятие — итеративный цикл градиентного спуска (10–30 шагов на стимул с адаптивной к), обучение — событийное, после стабилизации вывода [23, 26].

3.2. Иерархическое предиктивное кодирование Рао–Балларда

Конкретную сеть, реализующую спуск по свободной энергии, задали Рао и Баллард [19]: иерархия уровней, где каждый уровень l несёт оценку состояния x_l, предсказывает состояние уровня ниже через матрицу W_l, и сравнивает его с реальным сигналом уровня ниже. Ошибка предсказания — центральная переменная всей теории:

$$\hat{x}_l = f(W_l x_{l+1}), \qquad \varepsilon_l = x_l - \hat{x}_l$$ Уравнение (11)

Динамика уточнения состояний есть градиентный спуск по сумме квадратов ошибок всей иерархии, что для уровня l+1 даёт два слагаемых: нисходящий вклад $W^{\top}\varepsilon$ (вклад нижележащей ошибки, которую моё состояние предсказывает) и восходящий член $-\varepsilon_{l+1}$ (как моё состояние само не предсказано сверху):

$$\tau \dot{x}_{l+1} = (W_l^\top \varepsilon_l) \odot f'(W_l x_{l+1}) - \varepsilon_{l+1}$$ Уравнение (12)

Функция f — нелинейность генеративной модели, ⊙ — поэлементное умножение. Поток сигналов разнесён по архитектонике коры: восходящие проекции несут ошибки ε (тела клеток в верхних слоях), нисходящие — предсказания (глубокие слои) [19, 27]. Удивительно, что из этой схемы без учителя выводятся классические феномены V1: модели, минимизирующие ошибки на природных изображениях, самопроизвольно обретают рецептивные поля с антагонистическим центр-периферия (подавление избыточности) и «энд-стоппинг» — внеклассические эффекты, ради которых схема и создавалась [19].

Обучение весов в этой динамике локально: градиент энергии ошибки по W_l факторизуется по уровню l, и для квазилинейной f обновление принимает хеббовскую форму «ошибка ⊗ состояние»:

$$\Delta W_l = \eta\, \varepsilon_l\, x_{l+1}^\top \approx -\frac{\partial}{\partial W_l} \sum_k \tfrac{1}{2} \|\varepsilon_k\|^2 \qquad (f \approx \mathrm{id})$$ Уравнение (13)

В точности такой же вид имеют обновления backpropagation для линейного слоя; формальное соответствие между итеративным выводом (12) и обратным распространением ошибки установлено Уиттингтоном и Богачем и подробнее разобрано ниже. Сложность одного шага вывода — $O(n_l \cdot n_{l+1})$ на уровень (умножение на $W^\top$), для L уровней и T итераций — $O(T \cdot \Sigma\, n_l n_{l+1})$: константный множитель T ≈ 10–30 отличает «думающий» предиктивный слой от одного прохода backprop. Факторизация — стандартные трюки разреженных/низкоранговых $W^\top$.

3.3. Локальные правила, эквивалентность backprop и дендритная реализация

Уиттингтон и Богач показали [24], что предиктивная сеть с обновлениями (13) точно совпадает с backpropagation в специальном пределе: (а) нелинейность f линеаризована (f(x) ≈ x), (б) обратные веса связаны транспонированием с прямыми, (в) вывод по (12) доведён до стационара. Тогда стационарные значения ошибок ε_l пропорциональны δ backprop, и локальные обновления (13) воспроизводят градиент послойно — глобальный градиент возникает как стационарная точка локальной динамики. Ослабление условий (обратные связи без точной симметрии, нелинейные f) даёт приближённое совпадение, чего на практике достаточно: предиктивные сети решают MNIST/CIFAR-задачи

на уровне компактных backprop-сетей [24, 26]. Инженерная витрина направления — PredNet [25]: свёрточная рекуррентная сеть, где каждый слой передаёт вверх только отклонение от собственного предсказания, эффективно решает задачу предсказания видео и кодирует позы объектов без учителя. Библиотечная экосистема: ngc-learn — фреймворк нейрогенеративного кодирования с локальным обучением на JAX [63, 64]; репозиторий Predictive_Coding_Papers даёт аннотированную карту теории и кода [66].

Биологическая реализация ошибок — предмет активных работ, и здесь предиктивное кодирование смыкается с разделом 2. В микросхеме Сакраменто [17] ошибка backprop вычисляется не абстрактным «вычитателем», а апикальным дендритом, снабжённым интернейроном, который тормозным током вырезает предсказуемую часть нисходящего сигнала. Кальциевое плато (раздел 2.2) в этой логике — квантованный, пороговый сигнал «сильной непредсказанности», подлежащий ретрансляции вверх. Обратные проекции в такую архитектуру обязаны быть согласованы с прямыми, и Sacramento с соавторами показывают, что и это ограничение снимается: интернейронное торможение само обучается, извлекая линейную проекцию апикального сигнала (см. также обсуждение feedback alignment в [18]). Свободная энергия, таким образом, спускается до синапса в форме, не требующей ничего, кроме локально измеримых величин: пресинаптической активности, локального дендритного вклада и разлитой по нейрону ошибки.

3.4. Сводка механизма и псевдокод PyTorch

Сводка параметров формализма приведена в Таблице 2, полная реализация цикла вывода и локального обучения — в Листинге 2.

Таблица 2. Сводная карточка: предиктивное кодирование и свободная энергия

Уравнения	(9)–(13): свободная энергия F; градиентные спуски (10); ошибки (11); динамика вывода (12); локальное обучение ≈ backprop (13)
Переменные состояния	μ_l (оценки причин), ε_l (ошибки предсказания), W_l (синапсы), точности/дисперсии уровней
Численный метод	итеративный градиентный спуск по τ-динамике (12), T ≈ 10–30 шагов; обобщённые координаты состояний в динамической версии [21]
Связь с обучением	локальные хеббовские обновления (13); точная эквивалентность backprop при f ≈ id и симметричных весах [24]

Сложность	вывод: $O(T \cdot \Sigma\, n_l \cdot n_{l+1})$; обучение: как один backprop-шаг; факторизация низкоранговыми W
Ключевые ссылки	[19]–[27, 63]–[66]: Rao–Ballard; Friston 2005/2008/2010; Bogacz; Whittington–Bogacz; Lotter; Millidge; Jiang–Rao; ngc-learn

Листинг 2. Иерархическое предиктивное кодирование: вывод и локальное обучение

```
import torch

class PredictiveCodingNet(torch.nn.Module):
    """hPC-сеть (ур. 11-13): состояния x_l уточняются градиентным спуском
    по энергии ошибок E = 0.5 * sum ||eps_l||^2; обучение локальное."""
    def __init__(self, sizes, f=lambda z: torch.tanh(z)):
        super().__init__()
        self.f = f
        self.W = torch.nn.ModuleList([          # нисходящие предсказания W_l
            torch.nn.Linear(sizes[i+1], sizes[i], bias=False)
            for i in range(len(sizes)-1)])
        self.sizes = sizes

    @torch.no_grad()
    def infer(self, data, T=25, eta=0.05):
        """Вывод: цикл по (12) при фиксированных весах. Возвращает ошибки."""
        L = len(self.sizes)
        x = [None] * L
        eps = [None] * (L-1)
        x[0] = data                                  # низ иерархии фиксирован
        for l in range(1, L):                        # стартовая инициализация
            x[l] = torch.zeros_like(torch.randn(*data.shape[:-1], self.sizes[l]))
        for _ in range(T):
            for l in range(L-1):                     # предсказание и ошибка (11)
                pred = self.f(self.W[l](x[l+1]))
                eps[l] = x[l] - pred
            for l in range(1, L):                   # градиентный шаг по x_l (12)
                grad = self.W[l-1].weight.T @ eps[l-1]        # нисходящий член
                grad = grad * self.f(x[l])                    # нелинейность
                if l < L-1:
                    grad = grad - eps[l]                      # восходящий член
                x[l] = x[l] - eta * grad
        return x, eps

    def learn(self, x, eps, eta_w=1e-3):
        """Локальное правило (13): dW_l = eta * eps_l (x_{l+1})^T."""
        for l in range(len(self.W)):
            with torch.no_grad():
                self.W[l].weight += eta_w * eps[l].T @ self.f(x[l+1])

    def forward(self, data, T=25, eta=0.05, eta_w=1e-3):
        x, eps = self.infer(data, T, eta)
        self.learn(x, eps, eta_w)
        return x, eps
```

Листинг 2 реализует полный цикл предиктивного слоя: итеративный вывод по (12) с фиксацией входного уровня, локальное обучение по (13) и хранение всех переменных в явном виде. Для свёрточных данных каждую матрицу W заменяют свёрткой (так устроены PredNet [25] и Conv-NGC из ngc-learn [64]). Практический

параметр — число итераций вывода T: при T=1 сеть деградирует к кормлению ошибок «как есть», при больших T растёт время, но сходится к backprop-эквивалентности [24].

4. Теория эффективного кодирования

4.1. Сбалансированные сети и хаотическая динамика

Теория эффективного кодирования восходит к Атниву и Барлоу: сенсорные системы экономят нейронные ресурсы, отбрасывая статистическую избыточность стимула и оставляя почти независимые признаки [3, 4]. Балансированные возбуждающе-тормозные сети — динамический механизм, которым кортекс достигает этого баланса в реальном времени. ван Вресвейк и Сомполинский показали [28, 29], что крупные сети со сильными разреженными связями устойчиво самоорганизуются в режим, где средний возбуждающий и средний тормозной токи на каждый нейрон взаимно сокращаются, и лишь их остаточные флуктуации — порядка самих больших токов — остаются. Результат — асинхронная, иррегулярная, похожая на корковую активность при постоянном входе, причём генерируется она хаотической детерминированной динамикой, а не внешним шумом. Базовая модель — сеть скоростных нейронов со случайной связностью J_{ij}:

$$\tau \frac{dr_i}{dt} = -r_i + \varphi\left(\sum_{j=1}^{N} J_{ij} r_j + h_i\right), \qquad J_{ij} \sim \mathcal{N}(0,\, g^2/N) \qquad \text{Уравнение (14)}$$

где τ — мембранная постоянная, φ — передаточная функция, h_i — вход. Ключевой результат школы Сомполинского: при увеличении эффективного усиления g сеть в N→∞ пределе испытывает переход в хаос — прямой аналог механического перехода к хаосу в случайных нелинейных системах, найденный ещё в [30]: при $g > g_c \approx 1$ траектории расходятся экспоненциально, максимальный ляпуновский показатель положителен и растёт как $\lambda \propto (g - g_c)$, автокорреляции функции отклика имеют универсальную форму, а сеть «забывает» начальное состояние за время $1/\lambda$. Хаос здесь — не дефект, а ресурс: он обеспечивает бесконечный репертуар нетривиальных траекторий для кодирования и переключений состояния, и именно он служит источником «блуждающей» динамики (раздел 5.4).

Денев и Махенс связали строгий E/I-баланс с оптимальностью кода [31]: если сеть должна передавать изменения сигнала с максимально возможной точностью при ограничении на частоты, торможение обязано отслеживать возбуждение на миллисекундной шкале — так называемый «точный баланс», обнаруживаемый экспериментально. Эффективное кодирование, хаотическая динамика и баланс — три проекции одной конструкции. Современные биофизически детальные модели подтверждают выживание этих выводов при реалистичных проводимостных нейронах [32]. По реализации: уравнение (14) интегрируют явным Эйлером с шагом $\Delta\tau$; состояние — вектор r_i и матрица J_{ij}. Сложность шага — $O(N^2)$ при полной матрице, что на практике факторизуют низкоранговыми разложениями $J = UV^\top$ (K-мерные скрытые факторы): $O(N \cdot K)$ на шаг с сохранением хаоса; так же строятся аналитические mean-field решения.

4.2. Разрежённое кодирование: Olshausen–Field и локальное соревнование

Конструктивное определение «эффективного кода» дал эксперимент Ольсхаузена и Филда [33]: найди для природных изображений такой словарь Φ и такие коэффициенты a, чтобы каждый патч реконструировался точно, но активность коэффициентов была статистически редкой. Целевая функция — компромисс точности и разреженности:

$$E = \min_{\Phi,\, a} \left\{ \|I - \Phi a\|_2^2 \; + \; \lambda \sum_i S(a_i) \right\}$$

Уравнение (15)

где I — патч изображения, S — штраф за активность: вогнутая по модулю коэффициента функция, эквивалентная отрицательному логарифму априорного распределения с тяжёлыми хвостами; вогнутость делает малые коэффициенты «дешёвыми», а большие — «дорогими» по сравнению с квадратичным штрафом. Удивительный результат: без всякого супервизора оптимизация (15) порождает словарь, неотличимый от ориентированных, локализованных, полосовых рецептивных полей простых клеток V1. Обучение словаря — простое хеббовское правило «остаточная ошибка ⊗ активность», обновляющее каждый атом только в направлении его собственного вклада в ошибку, с последующей нормировкой:

$$\Delta\Phi \propto (I - \Phi a)a^{\top}, \qquad \Phi \leftarrow \mathrm{normalize}(\Phi)$$ Уравнение (16)

Вывод коэффициентов при фиксированном словаре — сама по себе динамическая задача, и Розелл с соавторами показали [34], что её решает локально конкурентный алгоритм (LCA): сеть из пороговых нейроноподобных узлов, каждый из которых соответствует атому словаря и ингибирует соседей через общий остаток. Динамика LCA:

$$\tau\frac{da_i}{dt} = -a_i + \phi_i^{\top}(I - \Phi a) - \lambda\frac{\partial S(a_i)}{\partial a_i}$$ Уравнение (17)

Активности ниже мягкого порога обнуляются — узел молчит; активные узлы соревнуются за объяснение патча, и система за конечное время сходится к разрежённому решению, близкому к результату централизованных методов погони (MP) и LASSO, но с локальными связями и аналоговой динамикой — в точности то, что кортикальный микросхемный уровень может исполнять аппаратно. Сложность вывода — $O(T_{infer}\cdot N_{атом}\cdot N_{пикс})$; обучение — $O(N_{атом}\cdot N_{пикс})$ на патч. При перекрывающемся (сверхполном) словаре $N_{атом} \gg N_{пикс}$ ингибицию можно факторизовать через грамиан $G = \Phi\Phi^{\top}$ — те же $O(N_{атом}^{2})$ на шаг, снижаемые низкоранговыми аппроксимациями.

4.3. Независимые компоненты: infomax и естественный градиент

Параллельная ветвь — анализ независимых компонент (ICA) Белла и Сейновски. Начав с принципа максимизации взаимной информации между входом и выходом (infomax [35]), они показали, что «развязывающие» фильтры W, применённые к природным сценам, — снова ориентированные краевые детекторы простых клеток [36]. Правило обучения — естественный градиент, исключающий медленную параметризацию пространства обратимых матриц:

$$\Delta W = \eta\left(I + g'(u)\,u^{\top}\right)W$$ Уравнение (18)

где $u = W\cdot I$ — оценки источников, g — нелинейность, связанная с предполагаемым распределением источников (супергауссовом — для изображений). Обновление (18) локально послойно и стабильно; на сходимость уходит порядка сотен эпох по патчам. Совпадение ICA-фильтров, sparse-словарей и рецептивных полей V1 — один из самых сильных аргументов того, что эффективное кодирование — не красивая метафора, а функциональная программа коры. Отметим: все три объекта

раздела 4 (балансированная сеть, LCA-разрежённость, ICA) допускают обучение без меток, без глобального градиента и на потоке данных — это «обучение представлению», которое в нейронных сетях первой ступени коры заменяет supervised-обучение целиком.

4.4. Сводка механизма и псевдокод PyTorch

Параметры формализма зафиксированы в Таблице 3; реализация LCA-вывода и хеббовского обучения словаря — в Листинге 3.

Таблица 3. Сводная карточка: эффективное кодирование

Уравнения	(14) — сбалансированная сеть; (15) — разрежённая цель; (17) — LCA-вывод; (16) — обучение словаря; (18) — ICA-естественный градиент
Переменные состояния	r_i и J_{ij} (баланс); a_i, Φ (sparse/ICA); остаточная ошибка $I - Φa$
Численный метод	явный Эйлер по τ; итеративный LCA-вывод; естественный градиент (18); mean-field стационары для (14)
Связь с обучением	без меток; хеббовские локальные правила (16), (18); точный E/I-баланс как сигнатура оптимальности [31]
Сложность	$O(N^2)$ на шаг (полная связность) → $O(N·K)$ низкоранговая; LCA: $O(T·N_{атом}·N_{пикс})$
Ключевые ссылки	[3]–[4]; [28]–[36]: Attneave; Barlow; van Vreeswijk–Sompolinsky; Sompolinsky et al.; Denève–Machens; Olshausen–Field; Rozell; Bell–Sejnowski

Листинг 3. Разрежённое кодирование: LCA-вывод и хеббовское обучение словаря

```
import torch

class SparseCoderLCA(torch.nn.Module):
    """Sparse coding (ур. 15-17): вывод — локально конкурентная динамика (17),
    обучение словаря — хеббовское правило (16). Без меток и градиентов."""
    def __init__(self, n_pix, n_atoms, lam=0.05, tau=10.0):
        super().__init__()
        self.Phi = torch.nn.Parameter(torch.randn(n_atoms, n_pix) / n_pix ** 0.5)
        self.lam, self.tau = lam, tau

    @torch.no_grad()
    def infer(self, I, T=200, dt=1.0):
        """LCA (15): b = Phi I; a_i обновляется пороговой динамикой."""
        b = self.Phi @ I                        # корреляционный отклик атомов
        G = self.Phi @ self.Phi.T               # грамиан ингибиции
        a = torch.zeros_like(b)
        for _ in range(T):
            resid = b - G @ a                   # остаток с учётом конкуренции
            support = resid.abs() > self.lam    # активное подмножество
            da = (-a + resid - self.lam * torch.sign(a)) / self.tau
            a = torch.where(support, a + dt * da, torch.zeros_like(a))
        return a

    def learn(self, patches, eta=1e-2):
        """(16): dPhi = eta * (I - Phi^T a) a^T + нормировка строк."""
        for I in patches:
```

```
            a = self.infer(I)
            err = I - self.Phi.T @ a          # остаточная ошибка реконструкции
            with torch.no_grad():
                self.Phi += eta * torch.outer(err, a)      # хеббовское ядро
                self.Phi /= self.Phi.norm(dim=1, keepdim=True) + 1e-8
        return self.Phi
```

Листинг 3 — компактная, но полная реализация классического цикла «вывод → обновление словаря». Для сбалансированной сети (14) прототип умещается в десяток строк: инициализация J с дисперсией g^2/N, цикл Эйлера по r, снятие автокорреляций; при g≈1.6 и φ = tanh сеть переходит в хаос, который регистрируется положительным ляпуновским показателем. ICA-правило (18) реализуется ещё короче: $W \leftarrow W + \eta(I + g'(u)u^{\top})W$ при u = W·I, g = tanh.

5. Аттракторные сети и динамика

5.1. Сети Хопфилда: память как энергетический ландшафт

Хопфилд в 1982 году совершил концептуальный ход, определивший поле на десятилетия: ассоциативная память — это динамическая система, спускающаяся по энергии [37]. Для бинарных нейронов $s_i \in \{-1,+1\}$ и симметричных весов функция

$$E(\mathbf{s}) = -\frac{1}{2}\sum_{i \neq j} w_{ij}\, s_i\, s_j, \qquad w_{ij} = \frac{1}{N}\sum_{\mu=1}^{p} \xi_i^{\mu}\, \xi_j^{\mu} \qquad \text{Уравнение (19)}$$

является функцией Ляпунова динамики: каждая асинхронная поправка нейрона по пороговому правилу

$$s_i(t+1) = \operatorname{sign}\!\left(\sum_j w_{ij}\, s_j(t) - \theta_i\right), \qquad p_{max} \approx 0.138\, N \qquad \text{Уравнение (20)}$$

не увеличивает E, и система гарантированно останавливается в локальном минимуме — «воспоминании». Запись образов ξ^{μ} выполняется хеббовским суммированием (правая часть (19)); шумный ключ, поданный как начальное состояние, спускается к ближайшему минимуму — автоассоциативный возврат. Ёмкость классической сети ограничена знаменитым числом Ами–Гутфрейнда–Сомполинского [38]: при p < 0.138·N воспроизведение устойчиво, при переполнении ландшафт разрушается в шпин-стекло и воспоминания «перемешиваются». Сложность шага — $O(N^2)$ умножений на полную связность; по памяти — $O(N^2)$ для весов, что стимулирует

факторизованные версии (ниже). Численно динамика (20) — событийно стохастическая: обновление случайного нейрона, шаг без итераций ODE — особенность, удобная для асинхронного железа.

5.2. Современные ассоциативные памяти: экспоненциальная ёмкость

Ограничение 0.138·N продержалось 30 лет, пока Кротов и Хопфилд не показали: если энергию строить не из попарных произведений, а из нелинейной функции от свёртки образа с состоянием, ёмкость растёт как степень размерности [39], а в пределе бесконечной степени взаимодействия — экспоненциально по N [40]. «Плотная ассоциативная память» (DAM) Кротова и Хопфилда [41] доводит идею до двухслойной сети с энергией

$$E(\mathbf{x}) = -\sum_{\mu=1}^{M} F\left(\xi_\mu^\top \mathbf{x}\right), \qquad \dot{\mathbf{x}} = -\nabla_{\mathbf{x}} E + \zeta(t) \qquad \text{Уравнение (21)}$$

где ξ_μ — хранимые образы (строки «нейронов памяти»), F — выбранная нелинейность (в [41] — SeLU-подобная), ζ — тепловой шум. Состояние обновляется градиентным спуском по (21) и сходится за считанные шаги. Ёмкость такой памяти экспоненциальна по числу видимых нейронов — двухслойность снимает узкое место попарных взаимодействий. Рамзауэр с соавторами [42] открыли вторую грань той же конструкции: конкретный выбор F = log-sum-exp даёт энергию

$$E(\mathbf{x}) = -\tfrac{1}{\beta}\log\sum_{\mu=1}^{M} e^{\beta \xi_\mu^\top \mathbf{x}} + \tfrac{1}{2}\|\mathbf{x}\|^2, \qquad \mathbf{x}^{new} = \Xi^\top \operatorname{softmax}(\beta \Xi\, \mathbf{x}) \qquad \text{Уравнение (22)}$$

и обновление (22) — в точности механизм внимания трансформера: softmax по образам даёт веса, а выход — их взвешенную сумму. Более того, для этой энергии доказана сходимость за один шаг и ёмкость, экспоненциальная по размерности ключей [42]. Так линейка «Хопфилд → DAM → attention» склеила нейробиологию ассоциативной памяти с архитектурой больших языковых моделей: ретрив данных из контекста — это спуск по энергии ассоциативной памяти. Сложность ретрива — O(M·d) на образ-запрос (M образов, d размерность), факторизуется проекциями в низкоранговое пространство ключей — ровно то, что делают multi-head проекции внимания.

5.3. Непрерывные аттракторы: интеграторы, кольца, карты

Дискретные минимумы — не единственный тип аттракторов: рабочая память и навигация требуют непрерывных многообразий устойчивых состояний — прямых, колец, торов. Канонический пример — нейронный интегратор глазной позиции, проанализированный Сыном [44]: сеть держит положение глаз между саккадами, и её устойчивые состояния образуют линейный аттрактор. Линейная редукция даёт систему

$$\dot{\mathbf{r}} = (W - \tau^{-1}\mathbb{I})\mathbf{r} + \mathbf{u}(t), \qquad \lambda_{max}(W - \tau^{-1}\mathbb{I}) \approx 0 \qquad \text{Уравнение (23)}$$

где u — толчковый вход (движение), r — активность. Постоянная память требует, чтобы максимум действительного спектра матрицы ($W - \tau^{-1}I$) был близок к нулю: тогда любая точка континуума — почти устойчивая, и интегрирование входа по времени сохраняется бесконечно долго. Тонкая настройка (23) чувствительна, и Сын с соавторами исследовали, как биофизически реалистичные механизмы (усиление, модуляция проводимостей) стабилизируют линейный аттрактор к шумам [45] — классический разбор компромисса «идеальная интеграция ↔ робастность».

Кольцевой аттрактор моделирует систему направления головы: популяция нейронов, настроенных на фазу φ_i, удерживает бамп активности, а сигнал угловой скорости непрерывно его сдвигает. Чжан [46] свела условия к симметриям весов:

$$\tau \frac{dr_i}{dt} = -r_i + \varphi\Big(\sum_j w(\phi_i - \phi_j)\, r_j + I_i^{ext}(t)\Big), \qquad w(\Delta\phi) = w_E e^{-\Delta\phi^2/2\sigma_E^2} - w_I e^{-\Delta\phi^2/2\sigma_I^2} \qquad \text{Уравнение (24)}$$

где $w(\Delta\varphi)$ — «мексиканская шляпа» (чётная часть, возбуждение − торможение), I^{ext} — внешний вход. Чётные веса стабилизируют форму бампа, малая нечётная компонента непрерывно сдвигает его со скоростью, пропорциональной амплитуде нечётной части — так сеть интегрирует угловую скорость и обновляет внутреннее представление направления. Обобщения на двумерные торы дают карты места Самсоновича и Макнотона [43]: «карты» (charts) — непрерывные аттракторы, по которым интеграция пути разворачивает когнитивную карту окружения. Во всех этих сетях переменная состояния — вектор активности r_i плюс матрица фиксированных весов; численно — явный Эйлер по τ с шагом 0,1–1 мс; сложность шага — $O(N^2)$, снижаемая

локальностью связей (w зависит от $\varphi_i - \varphi_j$, матрица теплицева → свёртка по кольцу, $O(N \cdot \log N)$ через БПФ или $O(N \cdot r_{\text{окно}})$ локальным окном).

5.4. Хаотическая блуждающая динамика (itinerancy)

Между жёсткими аттракторами и полностью хаотической динамикой лежит режим, названный Цудой хаотической блуждающей динамикой (chaotic itinerancy) [47]: траектория медленно странствует по фазовому пространству, попеременно «прилипая» к руинам аттракторов — Milnor-аттракторам, устойчивым по мере, но не по расстоянию. Математически это режим, где уничтоженные или наполовину разрушенные аттракторы (с непустым бассейном, но нулевым «объёмом» устойчивости) выстраиваются в последовательность; траектория посещает их поочерёдно, рождая длинные метастабильные плато, перебиваемые быстрыми переходами. Именно такую статистику демонстрирует спонтанная корковая активность: Кенет с соавторами [48] показали, что в анестезированном мозгу безмолвные состояния-«руины» соответствуют картам вызванной активности — мозг в покое «перебирает» те же представления, что и при стимуляции. Связь с балансированными сетями из раздела 4.1 прямая: хаотическое сбалансированное состояние — эргодический аналог itinerancy, в котором метастабильные кластеры активности сменяют друг друга без внешнего толчка [29, 47]. Для вычислений это режим «внутреннего перебора гипотез»: сеть, не запертая в аттракторе и не растворённая в шуме, сканирует пространство состояний, экономя внешний поиск. Численно itinerancy воспроизводится сетью (14) при g немного выше хаотического порога с медленной синаптической усталостью; либо сетью (21) с шумом ζ; сложность — как у порождающей сети, без дополнительных механизмов.

5.5. Сводка механизма и псевдокод PyTorch

Сводка формализма — в Таблице 4; листинги 4 и 5 реализуют оба полюса аттракторного спектра.

Таблица 4. Сводная карточка: аттракторные сети и динамика

Уравнения	(19)–(20) — энергия/динамика Хопфилда, ёмкость 0.138·N; (21)–(22) — современные ассоциативные памяти, = attention; (23) — линейный интегратор; (24) — кольцевой аттрактор; itinerancy — режим Milnor-аттракторов

Переменные состояния	s_i / r_i (состояния), w_{ij} (связность, часто фиксированная), для CAN — позиция бампа на многообразии
Численный метод	асинхронные пороговые обновления (классика); градиентный спуск по энергии; явный Эйлер по τ; свёртка/БПФ для теплицевых весов
Связь с обучением	Хебб (19); статические ассоциативные ретриверы; supervised-обучение DAM; внимание трансформера = одношаговый ретрив (22)
Сложность	классика $O(N^2)$/шаг, ёмкость $O(N)$; DAM: ретрив $O(M \cdot d)$, ёмкость экспоненциальна [40, 41]; CAN: $O(N^2) \to O(N \cdot \log N)$
Ключевые ссылки	[37]–[48]: Hopfield; AGS; Krotov–Hopfield; Demircigil; Ramsauer; Samsonovich–McNaughton; Seung; Zhang; Tsuda; Kenet

Листинг 4. Классический и современный Хопфилд: запись и ретрив

```
import torch

class HopfieldMemory:
    """Классическая (19)-(20) и современная (21)-(22) ассоциативная память."""
    def __init__(self, mode='classic', beta=1.0):
        self.mode, self.beta = mode, beta
        self.Xi = None          # матрица образов M x d

    def store(self, Xi):
        self.Xi = Xi
        if self.mode == 'classic':
            W = (Xi.T @ Xi) / Xi.shape[1]
            W.fill_diagonal_(0.0)
            self.W = W

    def retrieve(self, s, n_iter=25):
        if self.mode == 'classic':
            """Асинхронный спуск по энергии (20): доводит шумный ключ до ближайшего образа."""
            s = s.clone()
            for _ in range(n_iter):
                for i in torch.randperm(s.shape[0]):
                    s[i] = torch.sign(self.W[i] @ s)
            return s
        else:
            """Modern Hopfield (22): один шаг = attention-механизм."""
            logits = self.beta * (self.Xi @ s)         # энергии образов
            w = torch.softmax(logits, dim=0)           # веса по M образам
            return self.Xi.T @ w                       # новое состояние
```

Листинг 5. Кольцевой аттрактор: рабочая память направления

```
import torch

class RingAttractor(torch.nn.Module):
    """Кольцо (24): 'мексиканская шляпа' держит бамп; нечётная добавка
    интегрирует угловую скорость (Zhang, 1996). Эйлер по tau."""
    def __init__(self, N=180, tau=10e-3, dt=1e-3):
        super().__init__()
        self.N, self.tau, self.dt = N, tau, dt
        phi = torch.linspace(0, 2*torch.pi, N)
        d = phi[None,:] - phi[:,None]                        # разности фаз
        # чётная часть: локальное возбуждение минус широкое торможение
        W_even = 1.0*torch.exp(-(d**2)/(2*0.3**2)) - 0.8*torch.exp(-(d**2)/(2*1.2**2))
        # нечётная часть: сдвиг бампа пропорционален скорости vel
        W_odd = 0.5 * (torch.roll(W_even, 1, dims=1) - torch.roll(W_even, -1, dims=1))
        self.register_buffer('W_even', W_even)
        self.register_buffer('W_odd', W_odd)
        self.register_buffer('r', torch.zeros(N))

    def step(self, vel=0.0, I_ext=None):
        """Возвращает бамп; vel>0 — вращение по часовой."""
        inp = self.W_even @ self.r + vel * (self.W_odd @ self.r)
        if I_ext is not None:
            inp = inp + I_ext
        self.r = self.r + self.dt / self.tau * (-self.r + torch.relu(inp))
        return self.r
```

Листинги 4 и 5 покрывают оба полюса аттракторного мира: дискретную память с энергетическим спуском и непрерывное кольцо с интегрированием скорости. Комбинация даёт полный стек рабочей памяти: modern Hopfield — для ассоциативного доступа к содержимому (или бутстрапа attention-слоя [42]), кольцо/тор — для непрерывных переменных состояния вроде позиции и направления [43, 46].

6. Теория критичности

6.1. Ветвящиеся процессы и нейрональные лавины

Статистическая сигнатура корковой активности, породившая теорию критичности, — нейрональные лавины [49]: каскады спайков, распределения которых следуют степенным законам с показателями ориентированного ветвящегося процесса в критической точке. Минимальная модель — Гальтон–Уотсон: активный в момент t нейрон порождает в среднем σ потомков в момент t+1 (дискретизация времени — на медианном межспайковом интервале):

$$\sigma = \sum_{k=0}^{\infty} k\, p_k, \qquad \sigma_c = 1 :$$

$$P(S) \propto S^{-3/2}, \qquad P(D) \propto D^{-2} \qquad \text{Уравнение (25)}$$

При σ < 1 процесс вымирает (субкритический режим), при σ > 1 — разрастается бесконечно (суперкритический), и только при σ = 1 процесс точно сбалансирован: каскады любого масштаба, распределение $P(S) \propto S^{-3/2}$ по размеру и $P(D) \propto D^{-2}$ по длительности, а средний размер лавины длительности D растёт квадратично [49, 50]:

$$\langle S(D) \rangle \propto D^2 \qquad (\sigma = 1)$$ Уравнение (26)

Экспериментальные данные корковых срезов и культур ложатся на эти показатели с точностью в единицы процентов [49], а высокоразрешённый анализ подтверждает универсальность критических показателей и согласованность независимых подгонок — свидетельство того, что система действительно близка к ветвящейся критической точке, а не просто «степенная по жанру» [50].

6.2. Оценка параметра ветвления и режимы реальной коры

Параметр σ оценивается из временного ряда активности s_t (число активных нейронов в бине) регрессией потомков на родителей:

$$\hat{\sigma} = \frac{\sum_t s_t \, s_{t+1}}{\sum_t s_t^2}$$ Уравнение (27)

Оценка (27) несмещена при полных наблюдениях; при сэмплировании малой доли нейронов она систематически занижает σ, что подвигло Вилтинга и Приземанн построить устойчивые к неполноте максимально-правдоподобные оценки [57]. Их применение к многоэлектродным записям даёт нюансированную картину: живая кора чаще находится не строго в точке σ=1, а в узкой полосе вокруг неё — «реверберирующий» (слегка субкритический при слабом входе, слегка суперкритический при высоком) режим [57, 58], где система сохраняет критические бонусы, не взрываясь эпилептическими каскадами. Это же мотивирует концепцию «квазикритичности»: мозг конечного размера не может находиться строго в точке перехода, но динамически удерживается в его окрестности гомеостатическими механизмами.

6.3. Вычислительные выгоды критичности

Зачем сети балансировать на грани? Кинучи и Копелли дали количественный ответ: сеть возбудимых элементов имеет максимальный

динамический диапазон — способность различать входы на много порядков величины — точно в критической точке [51]:

$$\Delta = 10\log_{10}\left(\frac{F_{max}}{F_{min}}\right), \qquad \sigma \to \sigma_c \Rightarrow \Delta \to \Delta_{\text{opt}}$$ Уравнение (28)

где F — частота отклика сети, Δ — логарифмический диапазон входов, надёжно различимых по выходу. Восприимчивость (производная отклика по входу) расходится при σ→1, и сеть одинаково чувствительна к слабейшим касаниям и сильнейшим залпам — психофизическое «сжатие» стимула на миллисекундной шкале. Эксперименты Шью с соавторами подтвердили максимум динамического диапазона [52] и максимум пропускной способности/информационной ёмкости канала [53] при критическом ветвлении, управляемом фармакологией. Сводка преимуществ — в обзоре Шью–Пленца [54]: (1) максимальный динамический диапазон, (2) максимальная передача информации, (3) максимальное число метастабильных состояний-«слов» и, как следствие, репертуар для itinerancy раздела 5.4. Связь с обучением не градиентная, а гомеостатическая: к критичности приводят локальные правила — синаптическая депрессия/потенциация, масштабирование весов, баланс E/I — то есть «обучение режимом» без функции потерь; в ML-аналогии это гомеостатическая регуляризация, а не SGD. В reservoir computing критичность реализована как «край хаоса»: вычислительная мощность случайных рекуррентных сетей максимальна на границе порядка и хаоса [60, 61] — критичность есть оптимальный режим именно потому, что ляпуновский показатель ≈ 0: система хранит вход достаточно долго, чтобы его обработать, и достаточно гибко, чтобы не зациклиться.

6.4. Критика и границы применимости

Гипотеза критичности имеет и сильных оппонентов. Тубуль и Дестексе показали [55], что чисто стохастические процессы без всякого фазового перехода порождают степенные распределения, неотличимые наивными тестами от лавинных, — «степенной хвост» сам по себе не сертификат критичности. Дестексе и Тубуль далее продемонстрировали, что две заведомо некритические модели проходят полный набор критических статистик из широко цитируемых работ — ложные срабатывания методологии [59]. Беггс и Тимме суммировали возражения и пределы доказательной базы [56]: неоднозначность бинирования, несоблюдённая стационарность, принципиальные вопросы

фальсифицируемости. Корректная современная позиция: степенные статистики — необходимое, но не достаточное условие; обязательны контроли (суррогатные данные, subsampling-оценки [57], коллапс формы лавин [50]), и вывод «кора около критической точки» — это хорошо подкреплённая, но продолжающая уточняться гипотеза. Для инженера из этого следует практическое: не «тянуть» сеть в точку σ=1 насильно, а проверять, не даст ли узкая полоса квазикритичности [57, 58] тот же выигрыш устойчиво.

6.5. Сводка механизма и псевдокод PyTorch

Сводка формализма — в Таблице 5; симуляция ветвящегося процесса, оценка $\hat{\sigma}$ и проверка показателей — в Листинге 6.

Таблица 5. Сводная карточка: критичность

Уравнения	(25)–(28): ветвящийся процесс, $\sigma_c=1$; степенные законы $-3/2$ и -2; оценка $\hat{\sigma}$ (27); $\langle S(D)\rangle \propto D^2$ (26); динамический диапазон (28)
Переменные состояния	s_t (активность в бине), σ (параметр ветвления), распределение потомков p_k; для сети — E/I-баланс
Численный метод	дискретные поколения Гальтона–Уотсона; регрессионная (27) или maximum-likelihood оценка σ; бинирование времени
Связь с обучением	гомеостатические локальные правила (synaptic scaling, STDP) удерживают около $\sigma \approx 1$; внешнего градиента нет
Сложность	симуляция O(T); оценка (27) O(T); лавинная статистика O(T); network-версия — как у балансированной сети
Ключевые ссылки	[49]–[61]: Beggs–Plenz; Friedman; Kinouchi–Copelli; Shew; Touboul–Destexhe; Beggs–Timme; Wilting–Priesemann; Destexhe–Touboul; Bertschinger–Natschläger

Листинг 6. Ветвящийся процесс: симуляция лавин и оценка σ

```
import torch

def simulate_branching(sigma=1.0, T=200_000, p_ext=0.005, seed=0):
    """Гальтон-Уотсон (25): s_{t+1} | s_t ~ Poisson(sigma * s_t) + спонтанные.
    sigma<1 - вымирание; sigma=1 - критический; sigma>1 - взрыв."""
    g = torch.Generator().manual_seed(seed)
    s = torch.zeros(T)
    cur = 0
    for t in range(T):
        lam = sigma * cur
        cur = int(torch.poisson(torch.tensor(float(lam)), generator=g))
        if torch.rand(1, generator=g) < p_ext:
            cur += 1                    # редкий спонтанный триггер
        s[t] = cur
    return s

def estimate_sigma(s):
    """(27): регрессия потомков на родителей; несмещена при полных данных,
    занижает sigma при сильном subsampling (см. Wilting-Priesemann)."""
    num = (s[:-1] * s[1:]).sum()
```

```
    den = (s[:-1] ** 2).sum()
    return (num / (den + 1e-9)).item()

def avalanche_law(s, bins=25):
    """Лавины = всплески между нулями; проверка P(S) ~ S^-3/2 (25)."""
    sizes, cur = [], 0.0
    for x in s.tolist():
        if x > 0:
            cur += x
        elif cur > 0:
            sizes.append(cur); cur = 0.0
    if cur > 0:
        sizes.append(cur)
    S = torch.tensor(sizes)
    S = S[S > 0]
    hist = torch.histc(torch.log10(S), bins=bins)
    centers = torch.linspace(0, torch.log10(S.max()).item(), bins)
    sel = hist > 0
    slope = torch.polyfit(centers[sel], torch.log10(hist[sel]), 1)[0]
    return sizes, slope.item()   # slope ~ -3/2 в критической точке
```

Листинг 6 замыкает механический набор: симуляция ветвящегося процесса, оценка $\hat{\sigma}$ по (27) и степенная регрессия размеров лавин. Сигнатурный эксперимент: прогнать сеть из раздела 4.1 (балансированную) на трёх значениях усиления g и показать, что только узкая полоса около g_c даёт $\hat{\sigma} \approx 1$ и наклон $-3/2$ — так микросхема «режима» соединяется с микросхемами «субстрата» и «представления».

7. Синтез: пять формализмов как единый вычислительный стек

Формализмы, разобранные в разделах 2–6, не конкурируют — они ортогональны и комплементарны. Активные дендриты — локальные нелинейные подвычисления с трёхфакторной пластичностью: «hardware» одного нейрона. Предиктивное кодирование задаёт целевую функцию — свободную энергию, минимизируемую послойно локальными ошибками; именно ошибки предсказания, вычисляемые в апикальных дендритах и ретранслируемые кальциевыми плато, спускают глобальный градиент до уровня синапса ([16, 17, 24] — мост между разделами 2 и 3). Теория эффективного кодирования определяет, что именно кодировать в равновесном состоянии: словарь признаков с минимальной избыточностью, реализуемый сбалансированной хаотической сетью, которая попутно поставляет itinerancy — фон внутреннего перебора гипотез ([29, 31, 34] — мост между разделами 4 и 5). Аттракторы — устойчивые структуры поверх этого хаоса: от дискретных ландшафтов памяти до непрерывных карт пространства.

Критичность — режим, в котором сеть поддерживает максимальный динамический диапазон и репертуар метастабильных состояний для итераций этого перебора ([51, 53] — мост между разделами 5 и 6).

В терминах машинного обучения стек транслируется почти дословно. Двухслойный нейрон = перцептрон с one-hidden-layer и локальным правилом обучения, совместимым с backprop в глубине ([17, 18]). hPC-вывод = предобучение представления без меток + supervised-дообучение локальными ошибками ([24, 26]). Разрежённое кодирование = автоэнкодер с L1-штрафом и ингибиторной рекуррентностью ([33, 34]); ICA — его информационно-теоретический двойник ([35, 36]). Балансированная хаотическая сеть = эхо-состояние на краю хаоса, с усилением переходных процессов за счёт ненормальности связей ([29, 30]). Современный Хопфилд — внимание трансформера ([42]): единственный случай, где нейробиологический формализм буквальным образом стал промышленной ML-архитектурой. Критичность — критерий настройки гиперпараметров (усиление рекурренты, плотность E/I), который можно включить в целевую функцию как регуляризатор режима ([51, 56, 60]).

Интегральное сопоставление пяти механизмов приведено в Таблице 6.

Таблица 6. Интегральное сопоставление пяти механизмов

Механизм	Базовые уравнения	Правило обучения	Сложность (и факторизация)	Субстрат / аналог в ML
Дендритные вычисления	(1)–(8)	трёхфакторное локальное (7)–(8), ≈ backprop в иерархии	O(1)/синапс; O(N·K) по ветвям	апикальные/базальные дендриты; 2-слойный перцептрон на нейрон
Предиктивное кодирование / свободная энергия	(9)–(13)	локальные ошибки (13); точное = backprop при f≈id [24]	вывод O(T·Σ n·n′); обучение ≈ 1 backprop-шаг	кортикальная иерархия; PredNet, ngc-learn [25, 64]
Эффективное кодирование	(14)–(18)	Хебб без меток (16), (18); E/I-баланс гомеостазом	O(N²)→O(N·K); LCA: O(T·N_атом·N_пикс)	V1-подобные фильтры; автоэнкодер + L1 / ICA
Аттракторная динамика	(19)–(24)	Хебб (19); DAM обучаем supervised; attention-ретрив (22)	классика O(N²), ёмкость 0.138N; DAM O(M·d), ёмкость exp [40]	гиппокамп, интеграторы; Hopfield-слои трансформера [42]
Критичность	(25)–(28)	гомеостаз (synaptic scaling, E/I) — без функции потерь	симуляция/оценка O(T)	лавины коры; настройка reservoir на край хаоса [60, 61]

8. Ограничения и контраргументы

Корпус, представленный выше, — это конструкции с явными границами применимости, и честный обзор обязан их проговорить. Во-первых, редукция сложности: настоящие дендриты — распределённые ODE-системы с десятками типов каналов; двухкомпартментная модель (4)–(5) захватывает вычислительную суть (прогноз/ошибка), но теряет градиенты морфологии, неоднородность порогов ветвей и вклад ингибиторных дендритических входов. Во-вторых, эквивалентность предиктивного кодирования и backprop точна только в специальном пределе — линейная f, транспонированные обратные веса, стационарный вывод [24]; ослабления условий дают приблизительное соответствие, а устойчивость обучения обратных весов в нейронных реализациях остаётся активной проблемой (feedback alignment и интернейронное обучение апикального прогноза частично её решают [17, 18]).

В-третьих, аттракторная парадигма рабочей памяти сталкивается с экспериментальной критикой: в ряде задач персистентная активность отсутствует, а память поддерживается «безмолвно» — синаптическими следами с быстрым восстановлением [62]; непрерывные аттракторы требуют тонкой настройки (23), чувствительной к гетерогенности. В-четвёртых, критичность: степенные законы воспроизводятся некритическими процессами [55], стандартные тесты дают ложные срабатывания на контролах [59], и адекватная позиция — «около критичности» с надлежащими несмещёнными оценками [56, 57]. Наконец, свободная энергия — мета-framework: она совместима со многими микросхемами и потому уязвима к упрёку в слабой фальсифицируемости; её сила — организующая, а не предсказательная. Инженерные обобщения из раздела 7 следует воспринимать как гипотезы для бенчмарков, а не гарантированные выигрыши.

9. Заключение и следствия

Мы извлекли из теоретической нейробиологии пять математических механизмов, каждый из которых удовлетворяет строгому определению «вычислительного формализма»: явное уравнение, переменные состояния, численный метод, локальное правило обучения и проверяемые источники. Итоговая конструкция —

не список фактов, а стек: активные дендриты дают локальный субстрат нелинейностей и трёхфакторной пластичности; свободная энергия и предиктивное кодирование дают целевую функцию, спускающуюся до синапса как локальная ошибка предсказания; эффективное кодирование задаёт формат представления, реализуемый сбалансированной хаотической динамикой; аттракторные структуры — от Хопфилда до непрерывных карт — дают память и навигацию поверх этой динамики; критичность — режим максимальной чувствительности, в котором весь этот комплекс получает максимальный динамический диапазон и репертуар состояний.

Для исследователей NeuroAI из этого следует практическая программа. Каждый из пяти механизмов уже имеет компактную программную витрину ([63]–[67]), и каждый листинг настоящей статьи — 30–50 строк PyTorch — может быть включён в экспериментальный контур как drop-in-модуль: дендритный нейрон с правилом (7) вместо точечного перцептрона; hPC-цикл (11)–(13) вместо backprop-прохода при online-обучении; LCA-слой (15)–(17) как самообучающийся фронтенд сенсорики; Hopfield-ретрив (22) как слой внешней памяти; гомеостатическая настройка усиления по (25), (27) как регуляризатор режима. Открытыми остаются масштабирование дендритных схем до свёрточных глубин, устойчивое обучение обратных весов, несмещённая диагностика критичности в конкретном железе и интеграция пяти модулей в один обучающийся агент — именно эти задачи образуют повестку следующего цикла работ на стыке нейробиологии и машинного обучения.

Литература

[1] Herculano-Houzel S. (2009). The human brain in numbers: a linearly scaled-up primate brain. Frontiers in Human Neuroscience 3:31. https://www.frontiersin.org/articles/10.3389/neuro.09.031.2009/full (дата обращения: 23.10.2026).

[2] Attwell D., Laughlin S.B. (2001). An energy budget for signaling in the grey matter of the brain. Journal of Cerebral Blood Flow & Metabolism 21(10):1133–1145.

[3] Attneave F. (1954). Some informational aspects of visual perception. Psychological Review 61(3):183–193.

[4] Barlow H.B. (1961). Possible principles underlying the transformations of sensory messages. In: Rosenblith W.A. (ed.) Sensory Communication. MIT Press, Cambridge, MA, pp. 217–234.

[5] Stuart G.J., Sakmann B. (1994). Active propagation of somatic action potentials into neocortical pyramidal cell dendrites. Nature 367(6461):69–72. https://doi.org/10.1038/367069a0 (дата обращения: 23.10.2026).

[6] Magee J.C., Johnston D. (1997). A synaptically controlled, associative signal for Hebbian plasticity in hippocampal neurons. Science 275(5297):209–213. https://www.science.org/doi/10.1126/science.275.5297.209 (дата обращения: 23.10.2026).

[7] Larkum M.E., Zhu J.J., Sakmann B. (1999). A new cellular mechanism for coupling inputs arriving at different cortical layers. Nature 398(6725):338–341.

[8] Larkum M.E., Kaiser K.M.M., Sakmann B. (1999). Calcium electrogenesis in distal apical dendrites of layer 5 pyramidal cells at a critical frequency of back-propagating action potentials. PNAS 96(25):14600–14604. https://doi.org/10.1073/pnas.96.25.14600 (дата обращения: 23.10.2026).

[9] Schiller J., Major G., Koester H.J., Schiller Y. (2000). NMDA spikes in basal dendrites of cortical pyramidal neurons. Nature 404(6775):285–289.

[10] Jahr C.E., Stevens C.F. (1990). Voltage dependence of NMDA-activated macroscopic conductances predicted by single-channel kinetics. The Journal of Neuroscience 10(9):3178–3182. https://www.jneurosci.org/content/10/9/3178 (дата обращения: 23.10.2026).

[11] London M., Häusser M. (2005). Dendritic computation. Annual Review of Neuroscience 28:503–532. https://doi.org/10.1146/annurev.neuro.28.061604.135703 (дата обращения: 23.10.2026).

[12] Poirazi P., Mel B.W. (2001). Impact of active dendrites and structural plasticity on the memory capacity of neural tissue. Neuron 29(3):779–796. https://doi.org/10.1016/S0896-6273(01)00252-5 (дата обращения: 23.10.2026).

[13] Poirazi P., Brannon T., Mel B.W. (2003). Pyramidal neuron as two-layer neural network. Neuron 37(6):989–999. https://www.cell.com/neuron/fulltext/S0896-6273(03)00149-1 (дата обращения: 23.10.2026).

[14] Larkum M. (2013). A cellular mechanism for cortical associations: an organizing principle for the cerebral cortex. Trends in Neurosciences 36(3):141–151. https://doi.org/10.1016/j.tins.2012.11.006 (дата обращения: 23.10.2026).

[15] Larkum M.E. (2022). The guide to dendritic spikes of the mammalian cortex in vitro. Neuroscience & Biobehavioral Reviews 138. https://www.sciencedirect.com/science/article/pii/S030645222200063X (дата обращения: 23.10.2026).

[16] Urbanczik R., Senn W. (2014). Learning by the dendritic prediction of somatic spiking. Neuron 81(3):521–530. https://pubmed.ncbi.nlm.nih.gov/24507189 (дата обращения: 23.10.2026).

[17] Sacramento J., Costa R.P., Bengio Y., Senn W. (2018). Dendritic cortical microcircuits approximate the backpropagation algorithm. Advances in Neural Information Processing Systems 31 (NeurIPS 2018). https://papers.nips.cc/paper/8089-dendritic-cortical-microcircuits-approximate-the-backpropagation-algorithm (дата обращения: 23.10.2026).

[18] Guergiuev J., Lillicrap T.P., Richards B.A. (2017). Towards deep learning with segregated dendrites. eLife 6:e22901. https://elifesciences.org/articles/22901 (дата обращения: 23.10.2026).

[19] Rao R.P.N., Ballard D.H. (1999). Predictive coding in the visual cortex: a functional interpretation of some extra-classical receptive-field effects. Nature Neuroscience

2(1):79–87. https://www.nature.com/articles/nn0199_79 (дата обращения: 23.10.2026).

[20] Friston K. (2005). A theory of cortical responses. Philosophical Transactions of the Royal Society B 360(1456):815–836. https://doi.org/10.1098/rstb.2005.1622 (дата обращения: 23.10.2026).

[21] Friston K. (2008). Hierarchical models in the brain. PLoS Computational Biology 4(11):e1000211. https://doi.org/10.1371/journal.pcbi.1000211 (дата обращения: 23.10.2026).

[22] Friston K. (2010). The free-energy principle: a unified brain theory? Nature Reviews Neuroscience 11(2):127–138. https://www.nature.com/articles/nrn2787 (дата обращения: 23.10.2026).

[23] Bogacz R. (2017). A tutorial on the free-energy framework for modelling perception and learning. Journal of Mathematical Psychology 76B:198–211. https://www.sciencedirect.com/science/article/pii/S0022249615000759 (дата обращения: 23.10.2026).

[24] Whittington J.C.R., Bogacz R. (2017). An approximation of the error backpropagation algorithm in a predictive coding network with local learning rules. Philosophical Transactions of the Royal Society B 372(1713):20161013. https://doi.org/10.1098/rstb.2016.0213 (дата обращения: 23.10.2026).

[25] Lotter W., Kreiman G., Cox D. (2017). Deep predictive coding networks for video prediction and unsupervised learning. ICLR 2017; arXiv:1605.08104. https://arxiv.org/abs/1605.08104 (дата обращения: 23.10.2026).

[26] Millidge B., Seth A.K., Buckley C.L. (2021). Predictive coding: a theoretical and experimental review. arXiv:2107.12979. https://arxiv.org/abs/2107.12979 (дата обращения: 23.10.2026).

[27] Jiang L.P., Rao R.P.N. (2022). Predictive coding theories of cortical function. Annual Review of Neuroscience 45 (2022). arXiv:2112.10048. https://arxiv.org/abs/2112.10048 (дата обращения: 23.10.2026).

[28] van Vreeswijk C., Sompolinsky H. (1996). Chaos in neuronal networks with balanced excitatory and inhibitory activity. Science 274(5294):1724–1726. https://doi.org/10.1126/science.274.5294.1724 (дата обращения: 23.10.2026).

[29] van Vreeswijk C., Sompolinsky H. (1998). Chaotic balanced state in a model of cortical circuits. Neural Computation 10(6):1321–1371. https://pubmed.ncbi.nlm.nih.gov/9698348 (дата обращения: 23.10.2026).

[30] Sompolinsky H., Crisanti A., Sommers H.-J. (1988). Chaos in random neural networks. Physical Review Letters 61(3):259–262. https://doi.org/10.1103/PhysRevLett.61.259 (дата обращения: 23.10.2026).

[31] Denève S., Machens C.K. (2016). Efficient codes and balanced networks. Nature Neuroscience 19(3):375–382. https://doi.org/10.1038/nn.4243 (дата обращения: 23.10.2026).

[32] Koren V., Blanco Malerba S., Schwalger T., Panzeri S. (2024). Efficient coding in biophysically realistic excitatory-inhibitory spiking networks. eLife 13:RP99545. https://elifesciences.org/articles/99545 (дата обращения: 23.10.2026).

[33] Olshausen B.A., Field D.J. (1996). Emergence of simple-cell receptive field properties by learning a sparse code for natural images. Nature 381(6583):607–609. https://www.nature.com/articles/381607a0 (дата обращения: 23.10.2026).

[34] Rozell C.J., Johnson D.H., Baraniuk R.G., Olshausen B.A. (2008). Sparse coding via thresholding and local competition in neural circuits. Neural Computation

20(10):2526–2563. https://doi.org/10.1162/neco.2008.03-07-486 (дата обращения: 23.10.2026).

[35] Bell A.J., Sejnowski T.J. (1995). An information-maximization approach to blind separation and blind deconvolution. Neural Computation 7(6):1129–1159. https://doi.org/10.1162/neco.1995.7.6.1129 (дата обращения: 23.10.2026).

[36] Bell A.J., Sejnowski T.J. (1997). The «independent components» of natural scenes are edge filters. Vision Research 37(23):3327–3338. https://www.sciencedirect.com/science/article/pii/S0042698997001211 (дата обращения: 23.10.2026).

[37] Hopfield J.J. (1982). Neural networks and physical systems with emergent collective computational abilities. PNAS 79(8):2554–2558. https://doi.org/10.1073/pnas.79.8.2554 (дата обращения: 23.10.2026).

[38] Amit D.J., Gutfreund H., Sompolinsky H. (1985). Storing infinite numbers of patterns in a spin-glass model of neural networks. Physical Review Letters 55(14):1530–1533. https://doi.org/10.1103/PhysRevLett.55.1530 (дата обращения: 23.10.2026).

[39] Krotov D., Hopfield J.J. (2016). Dense associative memory for pattern classification. Advances in Neural Information Processing Systems 29:1172–1180. https://arxiv.org/abs/1606.01164 (дата обращения: 23.10.2026).

[40] Demircigil M., Heusel J., Löwe M., Upgang S., Vermet F. (2017). On a model of associative memory with huge storage capacity. arXiv:1702.01929. https://arxiv.org/abs/1702.01929 (дата обращения: 23.10.2026).

[41] Krotov D., Hopfield J.J. (2021). Large associative memory problem in neurobiology and machine learning. ICLR 2021; arXiv:2008.06996. https://arxiv.org/abs/2008.06996 (дата обращения: 23.10.2026).

[42] Ramsauer B., Schäfl B., Unterthiner T., Pils M., Hochreiter S. (2021). Hopfield networks is all you need. ICLR 2021; arXiv:2008.02217. https://arxiv.org/abs/2008.02217 (дата обращения: 23.10.2026).

[43] Samsonovich A., McNaughton B.L. (1997). Path integration and cognitive mapping in a continuous attractor neural network model. The Journal of Neuroscience 17(15):5900–5920. https://www.jneurosci.org/content/17/15/5900 (дата обращения: 23.10.2026).

[44] Seung H.S. (1996). How the brain keeps the eyes still. PNAS 93(23):13339–13344. https://doi.org/10.1073/pnas.93.23.13339 (дата обращения: 23.10.2026).

[45] Seung H.S., Lee D.D., Reis B.Y., Tank D.W. (2000). Stability of the memory of eye position in a recurrent network of conductance-based model neurons. Neuron 26(1):251–260.

[46] Zhang K. (1996). Representation of spatial orientation by the intrinsic dynamics of the head-direction cell ensemble. The Journal of Neuroscience 16(6):2112–2126. https://www.jneurosci.org/content/16/6/2112 (дата обращения: 23.10.2026).

[47] Tsuda I. (2001). Toward an interpretation of dynamic neural activity in terms of chaotic dynamical systems. Behavioral and Brain Sciences 24(5):793–847. https://philpapers.org/rec/TSUTAI (дата обращения: 23.10.2026).

[48] Kenet T., Bibitchkov D., Tsodyks M., Grinvald A., Arieli A. (2003). Spontaneously emerging cortical representations of visual attributes. Nature 425(6961):954–956. https://pubmed.ncbi.nlm.nih.gov/14586468 (дата обращения: 23.10.2026).

[49] Beggs J.M., Plenz D. (2003). Neuronal avalanches in neocortical circuits. The Journal of Neuroscience 23(35):11167–11177. https://www.jneurosci.org/content/23/35/11167

(дата обращения: 23.10.2026).

[50] Friedman N., Ito S., Brinkman B.A.W., Shimono M., DeVille R.E.L., Dahmen K.E., Beggs J.M., Butler T.C. (2012). Universal critical dynamics in high resolution neuronal avalanche data. Physical Review Letters 108(20):208102. https://doi.org/10.1103/PhysRevLett.108.208102 (дата обращения: 23.10.2026).

[51] Kinouchi O., Copelli M. (2006). Optimal dynamical range of excitable networks at criticality. Nature Physics 2(5):348–351. https://doi.org/10.1038/nphys289 (дата обращения: 23.10.2026).

[52] Shew W.L., Yang H., Petermann T., Roy R., Plenz D. (2009). Neuronal avalanches imply maximum dynamic range in cortical networks at criticality. The Journal of Neuroscience 29(49):15595–15600. https://www.jneurosci.org/content/29/49/15595 (дата обращения: 23.10.2026).

[53] Shew W.L., Yang H., Yu S., Roy R., Plenz D. (2011). Information capacity and transmission are maximized in balanced cortical networks with neuronal avalanches. The Journal of Neuroscience 31(1):55–61. https://www.jneurosci.org/content/31/1/55 (дата обращения: 23.10.2026).

[54] Shew W.L., Plenz D. (2013). The functional benefits of criticality in the cortex. The Neuroscientist 19(1):88–100. https://doi.org/10.1177/1073858412445487 (дата обращения: 23.10.2026).

[55] Touboul J., Destexhe A. (2010). Can power-law scaling and neuronal avalanches arise from stochastic dynamics? PLoS ONE 5(2):e8982. https://doi.org/10.1371/journal.pone.0008982 (дата обращения: 23.10.2026).

[56] Beggs J.M., Timme N.M. (2012). Being critical of criticality in the brain. Frontiers in Physiology 3:163. https://doi.org/10.3389/fphys.2012.00163 (дата обращения: 23.10.2026).

[57] Wilting J., Priesemann V. (2018). Inferring collective dynamical states from widely unobserved systems. Nature Communications 9:2201. https://www.nature.com/articles/s41467-018-04725-4 (дата обращения: 23.10.2026).

[58] Wilting J., Zierenberg J., Levina A., Priesemann V. (2019). A reverberating model captures and predicts cortical spike trains. Cerebral Cortex 29(6):2759–2771. https://academic.oup.com/cercor/article/29/6/2759/5476016 (дата обращения: 23.10.2026).

[59] Destexhe A., Touboul J.D. (2021). Is there sufficient evidence for criticality in cortical systems? eNeuro 8(2):ENEURO.0551-20.2021. https://doi.org/10.1523/ENEURO.0551-20.2021 (дата обращения: 23.10.2026).

[60] Bertschinger N., Natschläger T. (2004). Real-time computation at the edge of chaos in recurrent neural networks. Neural Computation 16(7):1413–1436. https://pubmed.ncbi.nlm.nih.gov/15165396 (дата обращения: 23.10.2026).

[61] Natschläger T., Bertschinger N., Legenstein R.A. (2004). At the edge of chaos: real-time computations and self-organized criticality in recurrent neural networks. Advances in Neural Information Processing Systems 17 (NIPS 2004). https://proceedings.neurips.cc/paper/2004/hash/f8da71e562ff44a2bc7edf3578c593da-Abstract.html (дата обращения: 23.10.2026).

[62] Stokes M.G. (2015). «Activity-silent» working memory: a new mechanism for persistent activity in cortical circuits. Trends in Cognitive Sciences 19(6):331–343.

[63] Ororbia A.G., Mali A., Kifer D., Giles C.L. (2022). The neural coding framework for learning generative models of sensory events. Scientific Reports 12 (2022). arXiv:2012.03405. https://arxiv.org/abs/2012.03405 (дата обращения: 23.10.2026).

[64] ngc-learn (2026). ngc-learn: Documentation, Version 3.2.3. Python-библиотека предиктивного кодирования (JAX). https://ngc-learn.readthedocs.io/en/latest/overview.html (дата обращения: 23.10.2026).

[65] coxlab/prednet (2017). PredNet: реализация PredNet на Keras (код к статье Lotter et al., ICLR 2017). https://github.com/coxlab/prednet (дата обращения: 23.10.2026).

[66] BerenMillidge/Predictive_Coding_Papers (2021). Аннотированная база работ по предиктивному кодированию с примерами кода. https://github.com/BerenMillidge/Predictive_Coding_Papers (дата обращения: 23.10.2026).

[67] unibe-cns/pal_microcircuits_genn (2020). Реализация дендритных микросхем Сакраменто на симуляторе GeNN (+ расширения Latent Equilibrium/PAL). https://github.com/unibe-cns/pal_microcircuits_genn (дата обращения: 23.10.2026).